



Université Claude Bernard



Lyon 1

PROJET DE MASTER 1

Etude, implémentation et comparaison de méthodes MCMC pour la calibration bayésienne de codes de calculs multiphysiques

Komlan Doigté Katakou

Frédérique Bienvenüe-Duheille (Encadrante)

Master 1 Mathématiques appliquées, Statistique, 2025 – 2026

Table des matières

Introduction	4
I Fondements théoriques	6
1 Modélisation du problème de calage	7
1.1 Formalisation du problème	7
1.1.1 Cadre général et notations	7
1.1.2 Modélisation probabiliste de l'écart modèle–mesure	7
1.2 Le cadre bayésien	8
1.2.1 Définition	8
1.2.2 Le mécanisme d'actualisation : la loi <i>a posteriori</i>	8
1.2.3 L'inférence bayésienne	9
1.2.4 L'inférence bayésienne	11
1.3 Méthodes d'échantillonnage classiques	13
1.3.1 Méthodes de quadrature déterministe : Fléau de la dimension	13
1.3.2 Méthode de Monte Carlo	14
1.3.3 Méthode du rejet	14
1.3.4 Échantillonnage préférentiel	15
1.3.5 De la nécessité des méthodes MCMC	17
2 Méthodes MCMC	18
2.1 Chaînes de Markov	18
2.1.1 Définition et propriété de Markov	18
2.1.2 Distribution stationnaire et réversibilité	19
2.1.3 Propriétés ergodiques	19
2.2 Algorithme de Metropolis–Hastings	20
2.2.1 Motivation	20
2.2.2 L'algorithme	21
2.2.3 Validité de l'algorithme	21
2.2.4 Le cas de la marche aléatoire	22
2.3 Méthodes adaptatives	22
2.3.1 Algorithme du rejet retardé	23
2.3.2 Metropolis adaptatif	25
2.3.3 DRAM : Delayed Rejection Adaptive Metropolis	27
2.4 Méthodes à gradient	29
3 Diagnostics de convergence	31
3.1 Diagnostic de Geweke	31
3.2 Diagnostic de Gelman–Rubin	32
3.3 Diagnostic de Raftery – Lewis	33

3.4	Taille effective d'échantillon (ESS)	37
II	Applications et résultats	38
4	Benchmark d'évaluation : cas jouets	39
4.1	Banane de Rosenbrock	39
4.1.1	Présentation	39
4.1.2	Résultats	40
4.2	Paysage de Rastrigin	40
4.2.1	Présentation	40
4.2.2	Résultats	40
4.3	Entonnoir de Neal	40
4.3.1	Présentation	40
4.3.2	Résultats	41
4.4	Gaussienne fortement corrélée en haute dimension	41
4.4.1	Présentation	41
4.4.2	Résultats	41
4.5	Synthèse	41
5	Applications réelles	43
	Conclusion	44
	Annexes	45
	Bibliographie	46

Remerciements

Introduction

L'analyse de systèmes physiques complexes repose de plus en plus sur l'utilisation de codes de calcul. En effet, dans le domaine de la sûreté nucléaire par exemple, certaines expérimentations physiques sont trop coûteuses, trop risquées, voire techniquement impossibles à réaliser. On leur substitue donc des modèles (simulateurs) numériques complexes, les codes de calcul, dont la fiabilité des prédictions est intrinsèquement liée à la précision des paramètres d'entrée. Ces paramètres, souvent mal connus ou issus d'hypothèses simplificatrices, entachent les sorties du modèle (lui-même étant une approximation de la réalité physique) d'incertitudes supplémentaires qu'il est impératif de quantifier pour l'aide à la décision et le calcul de marges de sécurité.

Caler ces paramètres pour que le simulateur reproduise fidèlement les quelques données réelles disponibles et quantifier l'incertitude résiduelle sur ces paramètres est donc une étape critique. Contrairement au calage déterministe qui cherche un unique vecteur de paramètres optimal solution d'un problème aux moindres carrés, l'approche bayésienne offre un cadre probabiliste plus complet. En combinant les croyances antérieures (*a priori*) à l'expérience, le plus souvent issues d'experts du domaine, et les observations réelles, cette approche permet d'estimer une distribution de probabilité complète des paramètres (*a posteriori*) et toute l'information utile (estimations, intervalles de crédibilité) s'en déduit par intégration. Or, l'inférence sur la distribution *a posteriori* se heurte souvent à une difficulté majeure : la fonction de densité n'est généralement connue qu'à une constante de normalisation près, une intégrale incalculable (même numériquement) pour des modèles non linéaires en grande dimension. Pour caractériser cette loi sans avoir recours à sa forme analytique complète, il devient indispensable de pouvoir l'échantillonner. Les approches classiques (rejet, importance sampling) pour échantillonner l'*a posteriori* échouent et gaspillent l'essentiel des évaluations du simulateur, chacune coûteuse. Les méthodes MCMC contournent cette impasse en remplaçant une loi de proposition globale par un noyau de transition markovien guidé par la densité locale, tirant ainsi parti au mieux de chaque appel au simulateur.

La première partie de ce mémoire présente le problème de calage comme un problème d'inférence dans le cadre de la modélisation bayésienne et présente les fondements théoriques des différentes méthodes MCMC. Nous passons ensuite à l'implémentation de toutes ces méthodes et à une étude comparative des résultats sur un benchmark de cas jouets bien choisis afin d'identifier les cas de succès (fortes corrélations, multimodalité, grande dimension) de chaque méthode, puis nous les déployons sur des cas d'étude concrets issus de l'industrie nucléaire et dont la provenance est tenue confidentielle.

Première partie

Fondements théoriques

Chapitre 1

Modélisation du problème de calage

1.1 Formalisation du problème

1.1.1 Cadre général et notations

Soit un système physique dont le comportement est modélisé par un *code de calcul* $f : \mathcal{X} \times \Theta \rightarrow \mathbb{R}^q$, où $\mathcal{X} \subseteq \mathbb{R}^p$ désigne l'espace des variables de contrôle (conditions expérimentales, géométrie, conditions aux limites, ...) et $\Theta \subseteq \mathbb{R}^d$ l'espace des paramètres incertains à calibrer. Pour un vecteur de paramètres $\theta \in \Theta$ et une condition expérimentale $x \in \mathcal{X}$, le code produit une prédiction $f_\theta(x) \in \mathbb{R}^q$.

On dispose d'un échantillon de n observations :

$$\mathcal{D}_n = \{(x_i, y_i)\}_{i=1}^n, \quad (1.1)$$

où $x_i \in \mathcal{X}$ est la i -ème condition expérimentale et $y_i \in \mathbb{R}^q$ la mesure physique correspondante, entachée d'une incertitude expérimentale.

1.1.2 Modélisation probabiliste de l'écart modèle-mesure

Le code de calcul f_θ n'étant qu'une approximation de la réalité physique, il existe un écart entre la prédiction $f_\theta(x_i)$ et la mesure y_i . Cet écart, noté ε_i , regroupe à la fois les erreurs de mesure et les insuffisances du modèle numérique. On le modélise par :

$$\exists \theta \in \Theta : \varepsilon_i := y_i - f_\theta(x_i) \sim \mathcal{N}(0, \sigma_{\varepsilon_i}^2) \quad \forall i = 1, \dots, n, \quad (1.2)$$

où la variance $\sigma_{\varepsilon_i}^2$, supposée connue, quantifie l'incertitude (de modèle et de mesure) au point x_i . Les erreurs $(\varepsilon_i)_{i=1}^n$ sont supposées indépendantes.

Remarque 1.1.1. *L'hypothèse de connaissance de $\sigma_{\varepsilon_i}^2$ est standard dans le cadre du calage de codes de calcul (KENNEDY et O'HAGAN 2001) : ces variances sont en général estimées à partir de répétitions des expériences ou fournies par le métrologue.*

Le modèle (1.2) est équivalent à supposer que les observations sont des réalisations de variables aléatoires gaussiennes centrées sur la prédiction du code :

$$y_i \sim Y_i \mid \theta, x_i \stackrel{\mathcal{L}}{=} \mathcal{N}(f_\theta(x_i), \sigma_{\varepsilon_i}^2). \quad (1.3)$$

Sous l'hypothèse d'indépendance des erreurs, la densité de probabilité jointe des observations $\mathbf{y} = (y_1, \dots, y_n)$ sachant θ se factorise en un produit de densités gaussiennes :

$$\pi(\mathbf{y} \mid \theta) = \prod_{i=1}^n \pi(y_i \mid \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi} \sigma_{\varepsilon_i}} \exp\left(-\frac{(y_i - f_\theta(x_i))^2}{2\sigma_{\varepsilon_i}^2}\right). \quad (1.4)$$

En passant au logarithme — ce qui est numériquement indispensable en pratique pour éviter les sous-dépassements de capacité (*underflow*) — la log-vraisemblance s'écrit :

$$\log \pi(\mathbf{y} \mid \theta) = -\frac{1}{2} \sum_{i=1}^n \frac{(y_i - f_\theta(x_i))^2}{\sigma_{\varepsilon_i}^2} - \sum_{i=1}^n \log(\sqrt{2\pi} \sigma_{\varepsilon_i}). \quad (1.5)$$

Remarque 1.1.2. Le premier terme de (1.5) est une somme des carrés des résidus pondérés par les incertitudes. Maximiser la vraisemblance revient donc à minimiser cette somme — ce qui coïncide avec l'estimateur des moindres carrés pondérés de l'approche déterministe classique. Le cadre bayésien présenté dans la section suivante enrichit cette vision en y incorporant une distribution *a priori* sur θ , permettant ainsi de quantifier l'incertitude résiduelle sur les paramètres après calage.

Remarque 1.1.3. Chaque évaluation de la vraisemblance (1.4) nécessite n appels au code de calcul f_θ . Un appel peut, selon l'application, durer de plusieurs minutes à plusieurs heures. Cela soulève donc une question d'efficacité pour les méthodes que nous devons déployer sur chacun de ces cas.

1.2 Le cadre bayésien

Contrairement à l'approche fréquentiste qui suppose l'existence d'une "vraie" valeur fixe θ_0 ayant généré les données, le paradigme bayésien considère le paramètre comme une variable aléatoire. Cette approche permet de modéliser explicitement l'incertitude sur les paramètres du code de calcul.

1.2.1 Définition

Un **modèle bayésien** est formellement défini par la donnée d'un couple $(\pi, \mathcal{P})$, où :

- $\pi(\theta)$ est la **loi *a priori*** (prior) définie sur l'espace des paramètres $\Theta \subset \mathbb{R}^d$. Elle représente l'état des connaissances sur θ avant toute observation.
- $\mathcal{P} = \{\pi(\cdot \mid \theta), \theta \in \Theta\}$ est une famille de lois conditionnelles, qui définit la distribution des observations $\mathbf{x}$ sachant un paramètre θ .

Dans ce cadre, l'aléa total du système est porté par la **loi jointe** $\pi(\theta, \mathbf{x})$. En vertu de la définition des probabilités conditionnelles, cette loi jointe se factorise comme le produit de la loi *a priori* et de la vraisemblance :

$$\pi(\theta, \mathbf{x}) = \pi(\mathbf{x} \mid \theta) \pi(\theta) \quad (1.6)$$

1.2.2 Le mécanisme d'actualisation : la loi *a posteriori*

L'objectif de l'inférence est d'inverser cette relation : connaissant une réalisation particulière des données $\mathbf{x}$, quelle est la loi de θ ? Par définition de la probabilité conditionnelle, la densité de θ sachant $\mathbf{x}$, dite **loi *a posteriori***, est le rapport entre la loi jointe et la loi marginale des observations :

$$\pi(\theta \mid \mathbf{x}) = \frac{\pi(\theta, \mathbf{x})}{\pi(\mathbf{x})} \quad (1.7)$$

La loi marginale $\pi(\mathbf{x})$, également appelée *évidence* ou *vraisemblance marginale*, s'obtient par intégration de la loi jointe sur tout l'espace des paramètres :

$$\pi(\mathbf{x}) = \int_{\Theta} \pi(\theta, \mathbf{x}) d\theta = \int_{\Theta} \pi(\mathbf{x} \mid \theta) \pi(\theta) d\theta \quad (1.8)$$

En combinant ces expressions, nous obtenons la forme classique du théorème de Bayes appliquée à l'inférence paramétrique :

$$\pi(\theta \mid \mathbf{x}) = \frac{\pi(\mathbf{x} \mid \theta) \pi(\theta)}{\int_{\Theta} \pi(\mathbf{x} \mid \theta) \pi(\theta) d\theta} \quad (1.9)$$

1.2.3 L'inférence bayésienne

Une fois la loi *a posteriori* $\pi(\theta|\mathbf{x})$ construite, l'étape d'inférence consiste à extraire des indicateurs synthétiques permettant de répondre aux problématiques de calage (estimation des paramètres et quantification d'incertitudes).

Estimation ponctuelle

L'estimation ponctuelle vise à fournir une valeur unique $\hat{\theta}$ représentative de la distribution *a posteriori* $\pi(\theta | \mathbf{x})$. Dans le cadre bayésien, le choix d'un estimateur est formellement lié à la minimisation d'une *fonction de perte* $\mathcal{L}(\theta, \hat{\theta})$, qui pénalise l'écart entre la vraie valeur θ et l'estimateur $\hat{\theta}$. L'estimateur bayésien optimal au sens de la perte $\mathcal{L}$ est celui qui minimise le *risque postérieur* :

$$\hat{\theta}^* = \arg \min_{\hat{\theta}} \mathbb{E}_{\pi(\theta|\mathbf{x})} [\mathcal{L}(\theta, \hat{\theta})] = \arg \min_{\hat{\theta}} \int_{\Theta} \mathcal{L}(\theta, \hat{\theta}) \pi(\theta | \mathbf{x}) d\theta. \quad (1.10)$$

Les trois estimateurs les plus fréquents découlent de trois fonctions de perte classiques.

1. **Espérance *a posteriori* (EAP).** Associée à la perte quadratique $\mathcal{L}_2(\theta, \hat{\theta}) = \|\theta - \hat{\theta}\|_2^2$, l'EAP minimise l'erreur quadratique moyenne *a posteriori*. On montre en effet que :

$$\frac{\partial}{\partial \hat{\theta}} \int_{\Theta} \|\theta - \hat{\theta}\|_2^2 \pi(\theta | \mathbf{x}) d\theta = 0 \iff \hat{\theta} = \mathbb{E}[\theta | \mathbf{x}],$$

ce qui donne un estimateur de l'EAP :

$$\hat{\theta}_{\text{EAP}} = \mathbb{E}[\theta | \mathbf{x}] = \int_{\Theta} \theta \pi(\theta | \mathbf{x}) d\theta. \quad (1.11)$$

2. **Maximum *a posteriori* (MAP).** Associé à la *perte zéro-un* $\mathcal{L}_{0-1}(\theta, \hat{\theta}) = \mathbf{1}_{\theta \neq \hat{\theta}}$, le MAP correspond au mode (le point le plus probable) de la distribution *a posteriori* :

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta \in \Theta} \pi(\theta | \mathbf{x}) = \arg \max_{\theta \in \Theta} \{\log \pi(\mathbf{x} | \theta) + \log \pi(\theta)\}. \quad (1.12)$$

Le MAP coïncide avec l'estimateur du maximum de vraisemblance (MLE) lorsque la loi *a priori* est uniforme sur Θ , auquel cas $\log \pi(\theta)$ est constant et disparaît de l'optimisation.

3. **Médiane *a posteriori*.** Associée à la *perte absolue* $\mathcal{L}_1(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$, la médiane *a posteriori* minimise l'erreur absolue moyenne. Pour un paramètre scalaire, elle est définie comme le quantile d'ordre 1/2 de la distribution *a posteriori* :

$$\hat{\theta}_{\text{Med}} = \inf \left\{ t \in \mathbb{R} : \int_{-\infty}^t \pi(\theta | \mathbf{x}) d\theta \geq \frac{1}{2} \right\}, \quad (1.13)$$

c'est-à-dire la valeur $\hat{\theta}$ telle que $\mathbb{P}(\theta \leq \hat{\theta} | \mathbf{x}) = 1/2$. Pour un vecteur de paramètres $\theta \in \mathbb{R}^d$, la médiane est calculée composante par composante. Elle est préférée à l'EAP lorsque la distribution est fortement asymétrique ou à queues lourdes, car elle est robuste aux valeurs extrêmes.

En pratique, ces trois estimateurs sont calculés à partir d'échantillons MCMC $\{\theta^{(t)}\}_{t=1}^T$:

$$\hat{\theta}_{\text{EAP}} \approx \frac{1}{T} \sum_{t=1}^T \theta^{(t)}, \quad (1.14)$$

$$\hat{\theta}_{\text{MAP}} \approx \arg \max_t \pi(\theta^{(t)} | \mathbf{x}), \quad (1.15)$$

$$\hat{\theta}_{\text{Med}} \approx \text{quantile}_{1/2}(\{\theta^{(t)}\}_{t=1}^T). \quad (1.16)$$

Indicateurs d'incertitude

L'inférence bayésienne ne se limite pas à l'obtention d'un estimateur ponctuel. Elle vise surtout à fournir une mesure de l'incertitude résiduelle sur les paramètres calés, caractérisée par des *régions de crédibilité* au sein de la distribution *a posteriori*.

1. **Régions de crédibilité** : Contrairement à l'intervalle de confiance fréquentiste — dont l'interprétation porte sur la procédure d'estimation et non sur le paramètre lui-même — l'intervalle de crédibilité bayésien possède une interprétation directe en termes de probabilité sur θ .

Définition 1.2.1 (Région de crédibilité). *Pour un niveau $1 - \alpha \in (0, 1)$ fixé, une région de crédibilité de niveau $1 - \alpha$ est un sous-ensemble mesurable $C_\alpha \subseteq \Theta$ tel que :*

$$\mathbb{P}(\theta \in C_\alpha \mid \mathbf{x}) = \int_{C_\alpha} \pi(\theta \mid \mathbf{x}) d\theta = 1 - \alpha. \quad (1.17)$$

Remarque 1.2.2. La condition (1.27) ne définit pas une région unique : il en existe une infinité satisfaisant cette contrainte de probabilité. Le choix d'une région parmi celles-ci requiert un critère supplémentaire — typiquement la minimalité du volume. C'est cet objectif qui motive la définition de la région HPD dans la sous-section suivante.

Remarque 1.2.3. En pratique, pour un paramètre scalaire, on utilise fréquemment l'**intervalle de quantiles** (equal-tailed interval), dont les bornes correspondent aux quantiles d'ordre $\alpha/2$ et $1 - \alpha/2$ de la distribution *a posteriori* :

$$C_\alpha^{\text{ET}} = [Q_{\alpha/2}, Q_{1-\alpha/2}], \quad (1.18)$$

où Q_p désigne le quantile d'ordre p de $\pi(\theta \mid \mathbf{x})$. Cet intervalle est simple à calculer par tri des échantillons MCMC, mais n'est pas optimal en termes de largeur lorsque la distribution est asymétrique.

2. **Régions de plus haute densité (HPD).**

Définition 1.2.4 (Région HPD). *La région de plus haute densité a posteriori (HPD, Highest Posterior Density) de niveau $1 - \alpha \in (0, 1)$ est définie par :*

$$C_\alpha^{\text{HPD}} = \{\theta \in \Theta : \pi(\theta \mid \mathbf{x}) \geq k_\alpha\}, \quad (1.19)$$

où k_α est la plus grande constante telle que $\mathbb{P}(\theta \in C_\alpha^{\text{HPD}} \mid \mathbf{x}) \geq 1 - \alpha$.

Proposition 1.2.5 (Propriétés de la région HPD). *La région HPD satisfait les deux propriétés suivantes :*

- (a) **Optimalité** : Pour un niveau $1 - \alpha$ donné, C_α^{HPD} est la région de crédibilité de volume minimal parmi toutes les régions satisfaisant la contrainte (1.27).
- (b) **Inclusion du mode** : Pour une distribution *a posteriori* unimodale, C_α^{HPD} contient systématiquement le mode (le MAP). Pour une distribution multimodale, la région HPD peut être non connexe et contenir plusieurs modes.

Démonstration. La propriété d'optimalité découle directement de la définition (1.29) : tout point $\theta \notin C_\alpha^{\text{HPD}}$ vérifie $\pi(\theta \mid \mathbf{x}) < k_\alpha$, donc a une densité inférieure à tout point inclus dans la région. Remplacer un tel point par un point extérieur de densité plus faible ne pourrait qu'augmenter le volume nécessaire pour atteindre la probabilité $1 - \alpha$ — ce qui contredit la minimalité. Pour la propriété d'inclusion du mode, il suffit de noter que le mode $\hat{\theta}_{\text{MAP}}$ est le maximum de $\pi(\theta \mid \mathbf{x})$, donc vérifie nécessairement $\pi(\hat{\theta}_{\text{MAP}} \mid \mathbf{x}) \geq k_\alpha$ pour tout $\alpha \in (0, 1)$. $\square$

Remarques

La formulation 1.9 met en évidence deux aspects fondamentaux pour la suite de nos travaux :

- **La règle de mise à jour** : Le posterior est proportionnel au produit du prior (connaissance initiale) et de la vraisemblance (apport des données expérimentales), soit :

$$\pi(\theta|\mathbf{x}) \propto \pi(\mathbf{x}|\theta)\pi(\theta) \quad (1.20)$$

- **L'intraitabilité de la constante** : Pour des codes de calcul complexes, l'intégrale $\pi(\mathbf{x})$ au dénominateur n'admet pas de forme analytique et son calcul numérique direct est prohibitif en haute dimension.

C'est précisément parce que nous ne connaissons le posterior qu'à une constante de normalisation près que nous devons chercher à l'échantillonner afin de pouvoir inférer là-dessus.

1.3 Méthodes d'échantillonnage classiques

Comme établi à la section précédente, toute quantité d'intérêt bayésienne — espérance *a posteriori*, région de crédibilité, probabilité d'un événement — se ramène structurellement au calcul d'une intégrale de la forme :

$$I(g) = \int_{\Theta} g(\theta) \pi(\theta | \mathbf{x}) d\theta, \quad (1.21)$$

où $g : \Theta \rightarrow \mathbb{R}$ est une fonction d'intérêt (identité pour l'EAP, indicatrice pour une région de crédibilité, *etc.*). Nous présentons ici les méthodes classiques d'approximation de cette intégrale, en soulignant leurs limites dans le contexte du calage, avant d'introduire les méthodes MCMC comme alternative naturelle.

1.3.1 Méthodes de quadrature déterministe : Fléau de la dimension

Les méthodes déterministes de quadrature (Trapèzes, Simpson, ...) approchent (1.31) en évaluant l'intégrande sur une grille régulière de Θ . En dimension 1, pour $n + 1$ points régulièrement espacés sur $[0, 1]$, le pas de grille est $h = 1/n$ et l'erreur d'une méthode de degré k ¹ est :

$$\epsilon_1 \approx \mathcal{O}(h^k) = \mathcal{O}(n^{-k}).$$

En dimension d , maintenir le même pas h sur un hypercube $[0, 1]^d$ requiert $N = n^d$ points au total. En exprimant h en fonction de N : $h = N^{-1/d}$, l'erreur devient :

$$\epsilon_d \approx \mathcal{O}(N^{-k/d}). \quad (1.22)$$

Pour maintenir une précision ϵ fixée, il faut donc $N = \mathcal{O}(\epsilon^{-d/k})$ points — une croissance *exponentielle* en la dimension d . Ce phénomène, connu sous le nom de *fléau de la dimension* (BELLMAN 1957), rend les méthodes de quadrature inutilisables dès que d dépasse une dizaine. Dans notre contexte, où d peut atteindre plusieurs dizaines de paramètres incertains et où chaque évaluation de l'intégrande nécessite un appel coûteux au simulateur f_θ , cette limitation est rédhibitoire.

1. Le *degré* k d'une méthode de quadrature désigne l'ordre du plus haut polynôme qu'elle intègre exactement : $k = 2$ pour la méthode des trapèzes, $k = 4$ pour Simpson, et $k = 2p - 1$ pour une règle de Gauss-Legendre à p points.

1.3.2 Méthode de Monte Carlo

L'approche Monte Carlo (METROPOLIS et ULAM 1949) contourne le fléau de la dimension en reformulant (1.31) comme une espérance :

$$I(g) = \mathbb{E}_{\theta \sim \pi(\cdot | \mathbf{x})}[g(\theta)],$$

estimée par la moyenne empirique de N tirages i.i.d. $\theta_1, \dots, \theta_N \sim \pi(\cdot | \mathbf{x})$:

$$\hat{I}_N = \frac{1}{N} \sum_{i=1}^N g(\theta_i). \quad (1.23)$$

Sous la condition de variance finie $\text{Var}_{\theta \sim \pi(\cdot | \mathbf{x})}[g(\theta)] < \infty$, le théorème central limite garantit que $\hat{I}_N$ converge en loi vers $I(g)$ et :

$$\sqrt{N} (\hat{I}_N - I(g)) \xrightarrow{\mathcal{L}} \mathcal{N}\left(0, \text{Var}_{\theta \sim \pi(\cdot | \mathbf{x})}[g(\theta)]\right), \quad (1.24)$$

d'où une erreur quadratique moyenne de l'ordre de :

$$\epsilon \approx \mathcal{O}\left(\frac{1}{\sqrt{N}}\right). \quad (1.25)$$

Remarque 1.3.1. Cette convergence en $\mathcal{O}(N^{-1/2})$ est indépendante de la dimension d — à comparer avec $\mathcal{O}(N^{-k/d})$ pour la quadrature. La méthode de Monte Carlo s'affranchit donc structurellement du fléau de la dimension, au prix d'une hypothèse forte : pouvoir simuler selon $\pi(\cdot | \mathbf{x})$. C'est précisément cette hypothèse qui ne peut être satisfaite directement, puisque $\pi(\cdot | \mathbf{x})$ n'est généralement connue qu'à une constante de normalisation près.

1.3.3 Méthode du rejet




FIGURE 1.1 – Illustration de la méthode du rejet sur un mélange de trois gaussiennes 1D : la densité cible π (bleu) est dominée par l'enveloppe Mq (orange pointillé), où $q = \mathcal{N}(1, 4^2)$ est la proposition. Les candidats $x \sim q$ sont acceptés (vert) si le point (x, U) , avec $U \sim \mathcal{U}(0, 1)$, tombe sous π , et rejetés (rouge) sinon.

La *méthode du rejet* (ROBERT et CASELLA 2009) permet de simuler exactement selon une densité cible π à partir d'une densité de proposition q plus simple à simuler, sous réserve de connaître π à une constante multiplicative près.

Hypothèse. On suppose qu'il existe une densité q simulable et une constante $M < \infty$ tels que :

$$\pi(x) \leq M q(x) \quad \forall x \in \mathcal{X}, \quad (1.26)$$

avec $M = \sup_{x \in \mathcal{X}} \pi(x)/q(x)$. La fonction Mq joue le rôle d'enveloppe de la densité cible.

Algorithme.

1. Simuler un candidat $x \sim q(\cdot)$ et indépendamment u selon la variable $U \sim \mathcal{U}(0, 1)$.
2. Accepter x si :

$$U \leq \frac{\pi(x)}{M q(x)}, \quad (1.27)$$

rejeter sinon et retourner à l'étape 1.

Proposition 1.3.2. *Tout x accepté par l'algorithme suit exactement la loi de densité π .*

Démonstration. Le couple (X, U) généré à l'étape 1 admet la densité jointe $q(x) \cdot \mathbf{1}_{[0,1]}(u)$. Puisque $U \sim \mathcal{U}(0, 1)$, la probabilité d'acceptation conditionnellement à x est :

$$\mathbb{P}(\text{acceptation} \mid x) = \mathbb{P}\left(U \leq \frac{\pi(x)}{M q(x)}\right) = \frac{\pi(x)}{M q(x)}.$$

La densité jointe de x et de l'événement "acceptation" est donc :

$$\mathbb{P}(x, \text{acceptation}) = q(x) \cdot \mathbb{P}(\text{acceptation} \mid x) = q(x) \cdot \frac{\pi(x)}{M q(x)} = \frac{\pi(x)}{M}.$$

En intégrant sur $\mathcal{X}$, la probabilité marginale d'acceptation est :

$$\mathbb{P}(\text{acceptation}) = \int_{\mathcal{X}} \frac{\pi(x)}{M} dx = \frac{1}{M}.$$

La densité conditionnelle de x sachant acceptation est alors :

$$p(x \mid \text{acceptation}) = \frac{p(x, \text{acceptation})}{\mathbb{P}(\text{acceptation})} = \frac{\pi(x)/M}{1/M} = \pi(x).$$

Tout x accepté suit donc exactement la loi de densité π . □

Limite en grande dimension. L'efficacité de la méthode est entièrement gouvernée par la quantité $1/M$: plus l'enveloppe Mq est lâche par rapport à π , plus M est grand et plus on rejette. Or, en grande dimension, trouver une enveloppe serrée devient structurellement impossible : la masse de π se concentre dans des régions de plus en plus fines de $\mathcal{X}$, tandis que toute proposition q raisonnable et aisément simulable doit couvrir un volume bien plus grand. La constante M croît alors très vite avec la dimension d , rendant la probabilité d'acceptation $1/M$ négligeable. Dans notre contexte, où $\pi = \pi(\cdot \mid \mathbf{x})$ est la loi *a posteriori* et où chaque évaluation nécessite un appel coûteux au simulateur f_θ , cette limitation est rédhibitoire : la quasi-totalité des appels est gaspillée sur des candidats rejetés.

1.3.4 Échantillonnage préférentiel

L'échantillonnage préférentiel (*importance sampling*) (RUBINSTEIN 1981) exploite l'identité de changement de mesure : pour toute densité de proposition q dont le support contient celui de π ,

$$I(g) = \int_{\mathcal{X}} g(x) \pi(x) dx = \int_{\mathcal{X}} g(x) \frac{\pi(x)}{q(x)} q(x) dx = \mathbb{E}_{X \sim q}[g(X) w(X)], \quad (1.28)$$

où $w(\cdot) = \pi(\cdot)/q(\cdot)$ est le *poids d'importance*.

Cas où π est entièrement connue. L'estimateur d'importance sampling est :

$$\hat{I}_{IS} = \frac{1}{N} \sum_{i=1}^N g(x_i) w(x_i), \quad x_i \stackrel{\text{i.i.d.}}{\sim} q, \quad (1.29)$$

qui est sans biais et converge vers $I(g)$ par la loi des grands nombres.

Cas où π n'est connue qu'à une constante près. En contexte bayésien, $\pi(x) = \gamma(x)/Z$ avec Z inconnu. On ne peut donc pas calculer $w(x) = \pi(x)/q(x)$ directement. On introduit les poids non normalisés $\tilde{w}(x) = \gamma(x)/q(x)$ et on remarque que :

$$\mathbb{E}_q[\tilde{w}(x)] = \int_{\mathcal{X}} \frac{\gamma(x)}{q(x)} q(x) dx = \int_{\mathcal{X}} \gamma(x) dx = Z, \quad (1.30)$$

de sorte que :

$$I(g) = \mathbb{E}_q[g(x) w(x)] = \frac{\mathbb{E}_q[g(x) \tilde{w}(x)]}{\mathbb{E}_q[\tilde{w}(x)]}. \quad (1.31)$$

En remplaçant chaque espérance par son estimateur empirique, on obtient l'estimateur auto-normalisé :

$$\hat{I}_{IS}^{\text{AN}} = \frac{\sum_{i=1}^N g(x_i) \tilde{w}(x_i)}{\sum_{i=1}^N \tilde{w}(x_i)}, \quad x_i \stackrel{\text{i.i.d.}}{\sim} q. \quad (1.32)$$

Cet estimateur est biaisé pour N fini mais consistant : par la loi des grands nombres (appliquée séparément au numérateur et au dénominateur) et le lemme de SLUTSKY, $\hat{I}_{IS}^{\text{AN}} \xrightarrow{p} I(g)$ quand $N \rightarrow \infty$.

Condition de stabilité. La variance de l'estimateur (1.39) s'écrit :

$$\text{Var}_q(\hat{I}_{IS}) = \frac{1}{N} \text{Var}_q[g(X) w(X)].$$

Par la formule $\text{Var}[Y] = \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2$ appliquée à $Y = g(x) w(x)$:

$$\text{Var}_q[g(X) w(X)] = \int_{\mathcal{X}} g(x)^2 \frac{\pi(x)^2}{q(x)} dx - I(g)^2.$$

Cette quantité est finie dès que g est bornée et que :

$$\int_{\mathcal{X}} \frac{\pi(x)^2}{q(x)} dx < \infty, \quad (1.33)$$

ce qui requiert que les queues de q soient au moins aussi lourdes que celles de π . Si cette condition est violée, l'estimateur est dominé par quelques échantillons de poids très élevés, rendant l'inférence erronée malgré une convergence apparente des moyennes.

Limite en grande dimension. Dès que q et π diffèrent légèrement dans leurs queues, la condition (1.43) est violée et la variance explose exponentiellement avec d (AGAPIOU et al. 2017). Construire une proposition q adaptée en grande dimension requiert une connaissance précise de π — connaissance que l'on cherche précisément à acquérir. C'est cette limitation structurelle qui motive le recours aux méthodes MCMC.

1.3.5 De la nécessité des méthodes MCMC

Le défaut commun de la méthode du rejet et de l'échantillonnage préférentiel est leur caractère *statique* : la loi de proposition q est fixée une fois pour toutes avant toute simulation, sans tenir compte de la topologie de $\pi(\cdot \mid \mathbf{x})$ découverte au fil des tirages.

L'intuition fondatrice des méthodes MCMC est de remplacer cette proposition globale $q(\theta)$ par une *transition locale* $K(\theta_{t+1} \mid \theta_t)$, c'est-à-dire une règle qui propose le prochain état à partir de l'état courant. En construisant une chaîne de Markov dont la distribution stationnaire est précisément $\pi(\theta \mid \mathbf{x})$, on transforme le problème de recherche d'une enveloppe globale, impossible en haute dimension, en un problème d'exploration locale progressive de Θ .

La transition K peut exploiter uniquement les évaluations de $\pi(\mathbf{x} \mid \theta) \pi(\theta)$ — c'est le cas de l'algorithme de Metropolis–Hastings — ou également le gradient $\nabla \log \gamma(\theta)$ pour orienter l'exploration vers les régions de forte densité — c'est le cas des algorithmes de Langevin (MALA) et Hamiltonien (HMC). Dans chacun de ces cas, la constante de normalisation Z se simplifie dans le ratio d'acceptation, ce qui rend ces algorithmes directement applicables à l'échantillonnage du posterior.

Chapitre 2

Méthodes MCMC

Les méthodes MCMC (*Markov Chain Monte Carlo*) reposent sur la construction d'une chaîne de Markov dont la distribution stationnaire coïncide avec la distribution cible π (le posterior) que l'on souhaite explorer. Avant de décrire ces algorithmes, nous rappelons les notions fondamentales relatives aux chaînes de Markov, en insistant sur les propriétés qui en font un outil adapté à l'échantillonnage.

2.1 Chaînes de Markov

Remarque 2.1.1. *Attention ! Cette théorie est présentée dans un cadre assez général : celui de l'échantillonnage d'une distribution cible π définie sur un espace $\mathcal{X} \subset \mathbb{R}^d$. Pour les applications bayésiennes qui nous intéressent, il s'agira de la loi a posteriori, définie sur un espace de paramètres $\times \subset \mathbb{R}^d$.*

2.1.1 Définition et propriété de Markov

On considère une suite de variables aléatoires $(X_n)_{n \geq 0}$ à valeurs dans $\mathcal{X} \subseteq \mathbb{R}^d$.

Définition 2.1.2 (Chaîne de Markov homogène). *La suite $(X_n)_{n \geq 0}$ est une chaîne de Markov homogène si, pour tout $n \geq 0$ et tout borélien $A \subseteq \mathcal{X}$:*

$$\mathbb{P}(X_{n+1} \in A \mid X_0, X_1, \dots, X_n) = \mathbb{P}(X_{n+1} \in A \mid X_n) \quad p.s., \quad (2.1)$$

et cette probabilité de transition ne dépend pas de n (homogénéité temporelle).

La condition (2.1), dite *propriété de Markov*, exprime l'absence de mémoire : l'évolution future de la chaîne ne dépend du passé qu'à travers l'état présent. C'est cette propriété qui rend les chaînes de Markov utilisables en simulation : il suffit de stocker l'état courant pour générer le suivant.

Définition 2.1.3 (Noyau de transition). *On appelle noyau de transition toute fonction $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ telle que, pour tout $x \in \mathcal{X}$, $y \mapsto k(x, y)$ est une densité de probabilité :*

$$k(x, y) \geq 0 \quad \text{et} \quad \int_{\mathcal{X}} k(x, y) \, dy = 1.$$

La loi de X_n se propage selon :

$$p_{n+1}(y) = \int_{\mathcal{X}} k(x, y) p_n(x) \, dx, \quad (2.2)$$

où p_n désigne la densité de X_n .

Remarque 2.1.4. *En pratique MCMC, le noyau k est défini algorithmiquement par une règle d'acceptation-rejet (par exemple, cf. section 2.2).*

2.1.2 Distribution stationnaire et réversibilité

Définition 2.1.5 (Distribution stationnaire). Une densité π sur $\mathcal{X}$ est dite stationnaire pour le noyau k si :

$$\pi(y) = \int_{\mathcal{X}} k(x, y) \pi(x) dx \quad \forall y \in \mathcal{X}. \quad (2.3)$$

Si $X_n \sim \pi$, alors $X_{n+1} \sim \pi$: la loi de la chaîne est constante au cours du temps.

Une condition suffisante simple pour garantir la stationnarité est la *réversibilité*.

Définition 2.1.6 (Réversibilité). Un noyau k est dit réversible par rapport à π s'il satisfait la condition de balance détaillée :

$$\pi(x) k(x, y) = \pi(y) k(y, x) \quad \forall x, y \in \mathcal{X}. \quad (2.4)$$

Proposition 2.1.7. Si k satisfait (2.4) par rapport à π , alors π est une distribution stationnaire de k .

Démonstration. En intégrant (2.4) par rapport à x :

$$\int_{\mathcal{X}} \pi(x) k(x, y) dx = \int_{\mathcal{X}} \pi(y) k(y, x) dx = \pi(y) \underbrace{\int_{\mathcal{X}} k(y, x) dx}_{=1} = \pi(y),$$

ce qui est précisément la condition (2.3). □

Remarque 2.1.8. La réversibilité est une condition suffisante, non nécessaire. Elle reste cependant le critère de conception central des algorithmes MCMC pour deux raisons : elle est simple à vérifier lors de la construction du noyau, et elle ne fait intervenir π qu'au travers du rapport $\pi(y)/\pi(x)$, ce qui permet de l'utiliser sans connaître la constante de normalisation de π , avantage décisif en modélisation bayésienne.

2.1.3 Propriétés ergodiques

Admettre une distribution stationnaire ne suffit pas : il faut que la chaîne *converge* vers cette distribution, indépendamment de l'état initial. Dans cette section, nous définissons quelques concepts puis énonçons quelques résultats notables de convergence. Pour la preuve de ces derniers, nous renvoyons à toute la théorie des chaînes de Markov qui n'est clairement pas l'objectif de ce mémoire.

Définition 2.1.9 (Irréductibilité). La chaîne est dite irréductible si, depuis tout état initial $x \in \mathcal{X}$, elle peut atteindre en un nombre fini de pas n'importe quelle région de $\mathcal{X}$ de mesure de Lebesgue λ positive :

$$\forall x \in \mathcal{X}, \forall A \subseteq \mathcal{B}(\mathcal{X}) \text{ tel que } \lambda(A) > 0, \exists n \geq 1 : \mathbb{P}(X_n \in A \mid X_0 = x) > 0.$$

Définition 2.1.10 (Apériodicité). La chaîne est dite apériodique si elle ne présente pas de comportement oscillatoire cyclique. En pratique, cela est vérifié dès lors qu'il existe une probabilité strictement positive que la chaîne reste sur place.

Théorème 2.1.11 (Convergence en distribution). Soit $(X_n)_{n \geq 0}$ une chaîne de Markov irréductible et apériodique admettant π comme distribution stationnaire. Alors, pour tout état initial x_0 :

$$p_n(\cdot \mid X_0 = x_0) \xrightarrow[n \rightarrow \infty]{d} \pi, \quad (2.5)$$

c'est-à-dire que la loi de X_n converge vers π indépendamment du point de départ.

Théorème 2.1.12 (Théorème ergodique (MEYN et TWEEDIE 1993)). *Sous les conditions du théorème 2.1.11, pour toute fonction $f : \mathcal{X} \rightarrow \mathbb{R}$ intégrable par rapport à π :*

$$\frac{1}{N} \sum_{n=1}^N f(X_n) \xrightarrow[N \rightarrow \infty]{\text{P.s.}} \mathbb{E}_\pi[f] := \int_{\mathcal{X}} f(x) \pi(x) dx. \quad (2.6)$$

Le théorème ergodique est la justification fondamentale des méthodes MCMC : il permet d’approcher toute espérance sous π par la moyenne temporelle d’une trajectoire de la chaîne, même si les X_n ne sont pas indépendants. C’est l’analogie de la loi des grands nombres pour les échantillons corrélés.

Remarque 2.1.13. *L’objectif des méthodes MCMC en inférence bayésienne est de construire un noyau k tel que $\pi(\theta \mid \mathbf{x})$ soit sa distribution stationnaire. Le théorème ergodique garantit alors que toute quantité d’intérêt bayésienne — EAP, région de crédibilité, probabilité d’événement — peut être estimée par moyenne empirique sur la trajectoire. La construction concrète d’un tel noyau fait l’objet des algorithmes présentées dans les sections ci-après.*

Théorème 2.1.14 (TCL pour chaînes de Markov, TIERNEY (1994)). *Sous les conditions du théorème 2.1.11, supposons de plus que la chaîne est géométriquement ergodique, c’est-à-dire qu’il existe $\rho \in (0, 1)$ et une fonction $V : \mathcal{X} \rightarrow [1, +\infty)$ tels que :*

$$\|p_n(\cdot \mid X_0 = x) - \pi\|_{TV} \leq V(x) \rho^n \quad \forall x \in \mathcal{X}, \forall n \geq 0,$$

où $\|\cdot\|_{TV}$ désigne la distance en variation totale. Alors, pour toute fonction $f : \mathcal{X} \rightarrow \mathbb{R}$ telle que $\mathbb{E}_\pi[f^2] < \infty$, la variance asymptotique :

$$\sigma_f^2 := \text{Var}_\pi(f) + 2 \sum_{k=1}^{+\infty} \text{Cov}_\pi(f(X_0), f(X_k)) \quad (2.7)$$

est finie, et on a la convergence en loi :

$$\sqrt{N} \left(\frac{1}{N} \sum_{n=1}^N f(X_n) - \mathbb{E}_\pi[f] \right) \xrightarrow[N \rightarrow \infty]{d} \mathcal{N}(0, \sigma_f^2). \quad (2.8)$$

Remarque 2.1.15. *La variance asymptotique σ_f^2 définie en (2.7) joue un rôle central dans l’évaluation de l’efficacité des algorithmes MCMC. Elle se décompose en deux termes : la variance sous π d’une seule observation, et une somme de covariances qui mesure la dépendance temporelle le long de la trajectoire. Plus les états successifs de la chaîne sont corrélés, plus cette somme est grande et moins l’estimateur est précis. C’est précisément cette quantité que l’algorithme du rejet retardé cherche à minimiser, au sens de l’ordre de Peskun (cf. section 2.3).*

2.2 Algorithme de Metropolis–Hastings

2.2.1 Motivation

L’idée de METROPOLIS, ROSENBLUTH et al. (1953), généralisée par HASTINGS (1970), est de corriger une distribution de proposition arbitraire $q(\cdot \mid x)$ par une étape d’acceptation-rejet garantissant la condition de réversibilité (2.4).

Plutôt que de viser une représentation globale de π dès le premier tirage — comme le ferait l’algorithme du rejet — la chaîne construit une image progressive de la distribution cible par exploration locale de l’espace $\mathcal{X}$, ne nécessitant l’évaluation de π qu’à une constante de normalisation près, conformément à la relation (1.30).

2.2.2 L'algorithme

Définition 2.2.1 (Noyau de proposition). *On appelle noyau de proposition une densité conditionnelle $q : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ telle que, pour tout $x \in \mathcal{X}$, $y \mapsto q(y | x)$ est une densité de probabilité.*

La transition de Metropolis–Hastings est définie comme suit.

Algorithme 1 : Metropolis–Hastings

Entrée : État courant $x^{(t)}$, densité cible non normalisée $\tilde{\pi}$, noyau de proposition q

Sortie : Nouvel état $x^{(t+1)}$

- 1 Simuler $y \sim q(\cdot | x^{(t)})$;
- 2 Calculer le ratio d'acceptation :

$$\rho(x^{(t)}, y) = \min \left\{ \frac{\tilde{\pi}(y)}{\tilde{\pi}(x^{(t)})} \cdot \frac{q(x^{(t)} | y)}{q(y | x^{(t)})}, 1 \right\}$$

- 3 Simuler une réalisation u de $U \sim \mathcal{U}(0, 1)$;
 - 4 **if** $u \leq \rho(x^{(t)}, y)$ **then**
 - 5 $x^{(t+1)} \leftarrow y$ // acceptation
 - 6 **else**
 - 7 $x^{(t+1)} \leftarrow x^{(t)}$ // rejet
-

Remarque 2.2.2. Le ratio ρ ne fait intervenir π qu'au travers du rapport $\tilde{\pi}(y) / \tilde{\pi}(x^{(t)})$: la constante de normalisation Z se simplifie, ce qui rend l'algorithme applicable dès lors que π est connue à une constante près — situation typique de l'inférence bayésienne (cf. équation (1.30)).

Remarque 2.2.3. Dans le cadre de l'inférence bayésienne où la densité cible $\tilde{\pi}$ sera le posterior $\pi(\theta | x)$ à la constante de normalisation près, l'état de l'algorithme à l'itération t sera noté $\theta^{(t)}$.

2.2.3 Validité de l'algorithme

Nous établissons ici que l'algorithme 1 produit bien une chaîne de Markov convergeant vers la distribution cible π . La démonstration se déroule en deux temps : on montre d'abord que π est stationnaire pour le noyau de transition k_{MH} , puis on admet les conditions supplémentaires garantissant la convergence.

Proposition 2.2.4. *Le noyau de transition k_{MH} défini par l'algorithme 1 satisfait la condition de réversibilité (2.4) par rapport à π . En particulier, π est une distribution stationnaire de k_{MH} .*

Démonstration. Le noyau k_{MH} se décompose en une partie continue et une masse ponctuelle. Pour $v \neq u$, la densité de transition est :

$$k_{\text{MH}}(x, y) = q(y | x) \rho(x, y).$$

En $y = x$, le noyau place une masse ponctuelle de probabilité

$$1 - \int_{\mathcal{X}} q(y | x) \rho(x, y) dy,$$

correspondant à la probabilité de rejet. La réversibilité de la partie ponctuelle est triviale : $\pi(x) r(x) = \pi(x) r(x)$.

Il reste à vérifier la réversibilité pour la partie continue. Pour $v \neq u$, on veut montrer :

$$\pi(x) q(y | x) \rho(x, y) = \pi(y) q(x | y) \rho(y, x).$$

Sans perte de généralité, supposons que $\pi(x) q(y | x) \geq \pi(y) q(x | y)$. Par définition de ρ :

$$\rho(x, y) = \frac{\pi(y) q(x | y)}{\pi(x) q(y | x)}, \quad \rho(y, x) = 1.$$

On calcule les deux membres :

$$\begin{aligned} \pi(x) q(y | x) \rho(x, y) &= \pi(x) q(y | x) \cdot \frac{\pi(y) q(x | y)}{\pi(x) q(y | x)} = \pi(y) q(x | y), \\ \pi(y) q(x | y) \rho(y, x) &= \pi(y) q(x | y) \cdot 1 = \pi(y) q(x | y). \end{aligned}$$

Les deux membres sont égaux, ce qui établit la réversibilité. Par la proposition de la section 2.1.2, π est donc une distribution stationnaire de k_{MH} . $\square$

Pour conclure quant à la convergence de la chaîne, il faut de plus vérifier les conditions d'irréductibilité et d'apériodicité du théorème 2.1.11.

Remarque 2.2.5 (Conditions de convergence). • **Irréductibilité** : une condition suffisante est que $q(\cdot | x)$ soit positive sur le support de π pour tout $x \in \mathcal{X}$. Sous cette hypothèse, la chaîne peut atteindre toute région de probabilité positive depuis n'importe quel point de départ.

• **Apériodicité** : garantie dès que la probabilité de rejet est strictement positive, c'est-à-dire dès qu'il existe v tel que $\rho(x, v) < 1$, ce qui est le cas générique en pratique.

La démonstration formelle de ces deux propriétés sous des conditions générales dépasse le cadre de ce mémoire ; on renvoie à ROBERT et CASELLA (2004) pour les détails. Nous admettons qu'elles sont satisfaites pour toutes les distributions de référence utilisées dans la partie II, pour lesquelles q est choisie gaussienne et donc positive partout.

Par la proposition 2.2.4 et la remarque 2.2.5, les conditions du théorème 2.1.11 sont satisfaites. On conclut que l'algorithme de Metropolis–Hastings produit une chaîne de Markov convergeant vers la distribution cible π pour tout point de départ.

2.2.4 Le cas de la marche aléatoire

Une configuration particulièrement répandue est celle où la proposition est une *marche aléatoire* centrée à l'état courant de la chaîne. Le candidat est généré par :

$$y = x^{(t)} + \varepsilon_t, \quad \varepsilon_t \sim G,$$

où G a une densité g symétrique autour de zéro. Cette symétrie implique :

$$q(y | x) = g(y - x) = g(x - y) = q(x | y),$$

de sorte que le ratio de propositions vaut identiquement 1. La probabilité d'acceptation se réduit alors à :

$$\rho(x, y) = \min \left\{ \frac{\tilde{\pi}(y)}{\tilde{\pi}(x)}, 1 \right\}. \quad (2.9)$$

Les candidats plus probables que l'état courant sont toujours acceptés ; les candidats moins probables sont acceptés avec une probabilité égale au ratio des densités.

2.3 Méthodes adaptatives

L'algorithme de Metropolis–Hastings (MH) présente une inefficacité structurelle : lors d'un rejet, la chaîne reste en $x^{(t)}$ et avance le temps (le nombre d'itérations) sans explorer l'espace

$\mathcal{X}$. Ce comportement a une conséquence directe sur la qualité des estimateurs MCMC. Par le théorème 2.1.14, la variance asymptotique de l'estimateur $\frac{1}{N} \sum_{t=1}^N f(X_t)$ est :

$$\sigma_f^2 = \text{Var}_{X \sim \pi}(f(X)) + 2 \sum_{k=1}^{+\infty} \text{Cov}_{\pi}(f(X_0), f(X_k)). \quad (2.10)$$

Lorsque la chaîne reste en place, les termes $f(X_t)$ successifs sont identiques, ce qui gonfle les covariances et donc σ_f^2 . Réduire le nombre de rejets est donc une voie directe pour améliorer l'efficacité des estimateurs.

2.3.1 Algorithme du rejet retardé

TIERNEY et MIRA (1999) avancent une idée simple : lors d'un rejet, plutôt que de rester en $x^{(t)}$, on *retarde* la décision de rester en place en proposant un nouveau candidat depuis une distribution q_2 différente de q_1 . Ce mécanisme, appelé *rejet retardé* (*Delayed Rejection*, DR), est formalisé et étudié par MIRA (2001) qui montre qu'il améliore MH au sens de l'ordre de Peskun.

Définition 2.3.1 (Ordre de Peskun, PESKUN (1973)). Soient P_1 et P_2 deux noyaux de transition réversibles par rapport à π . On dit que P_1 domine P_2 au sens de Peskun si, pour tout $x \neq y$:

$$P_1(x, \{y\}) \geq P_2(x, \{y\}).$$

PESKUN (1973) montre que si P_1 domine P_2 au sens de Peskun, alors pour toute fonction f de variance finie sous π :

$$\sigma_{f,P_1}^2 \leq \sigma_{f,P_2}^2.$$

L'ordre de Peskun formalise l'intuition suivante : un noyau qui se déplace plus souvent produit des estimateurs de variance asymptotique plus faible, uniformément sur toutes les fonctions f .

L'algorithme à deux étages

Supposons que la chaîne est en $x^{(t)} = x$. Comme dans MH, on propose un premier candidat $y_1 \sim q_1(\cdot | x)$ et on l'accepte avec la probabilité usuelle :

$$\alpha_1(x, y_1) = 1 \wedge \frac{\pi(y_1) q_1(x | y_1)}{\pi(x) q_1(y_1 | x)} =: 1 \wedge \frac{N_1}{D_1}. \quad (2.11)$$

Si y_1 est accepté, on pose $x^{(t+1)} = y_1$ et l'itération est terminée. Si y_1 est *rejeté* — c'est-à-dire si $N_1 < D_1$ — plutôt que de poser $x^{(t+1)} = x$, on propose un second candidat $y_2 \sim q_2(\cdot | x, y_1)$, où q_2 peut dépendre du candidat rejeté y_1 .

La probabilité d'acceptation $\alpha_2(x, y_1, y_2)$ doit être calculée de façon à préserver la réversibilité par rapport à π pour le noyau de transition modifié.

La contribution au noyau de transition correspondant au chemin $x \rightarrow y_1$ (rejeté) $\rightarrow y_2$ (accepté) est :

$$P^{(2)}(x, dy_2) = \int q_1(y_1 | x) [1 - \alpha_1(x, y_1)] q_2(y_2 | x, y_1) \alpha_2(x, y_1, y_2) dy_1.$$

La réversibilité pour ce chemin exige que le flux de x vers y_2 via y_1 soit égal au flux de y_2 vers x via y_1 . (MIRA 2001) choisit de forcer le chemin retour à être le miroir exact du chemin aller : depuis y_2 , on propose y_1 , on le rejette, puis on accepte x . Sous cette convention, on écrit la balance détaillée qui permet d'obtenir aisément :

$$\alpha_2(x, y_1, y_2) = 1 \wedge \frac{\pi(y_2) q_1(y_1 | y_2) q_2(x | y_2, y_1) [1 - \alpha_1(y_2, y_1)]}{\pi(x) q_1(y_1 | x) q_2(y_2 | x, y_1) [1 - \alpha_1(x, y_1)]} =: 1 \wedge \frac{N_2}{D_2}. \quad (2.12)$$

Mais, si le deuxième étage est atteint, c'est que y_1 a été rejeté au premier, donc $\alpha_1(x, y_1) = N_1/d_1$ et l'on peut écrire $1 - \alpha_1(x, y_1) = (D_1 - N_1)/D_1$. En substituant dans D_2 , on obtient la formule simplifiée :

$$\alpha_2(x, y_1, y_2) = 1 \wedge \frac{N_2}{q_2(y_2 | x, y_1) (D_1 - N_1)}. \quad (2.13)$$

L'algorithme à m étages

Le mécanisme de rejet retardé peut être itéré. Si le candidat y_{i-1} proposé à l'étage $i - 1$ est rejeté, on génère $y_i \sim q_i(\cdot | x, y_1, \dots, y_{i-1})$ et on l'accepte avec la probabilité (MIRA 2001) :

$$\alpha_i(x, y_1, \dots, y_i) = 1 \wedge \frac{\pi(y_i) q_1(y_i, y_{i-1}) \cdots q_i(y_i, \dots, x)}{\pi(x) q_1(x, y_1) \cdots q_i(x, \dots, y_i)} \cdot \frac{\prod_{j=1}^{i-1} [1 - \alpha_j(y_i, \dots, y_{i-j})]}{\prod_{j=1}^{i-1} [1 - \alpha_j(x, y_1, \dots, y_j)]} =: 1 \wedge \frac{N_i}{D_i}. \quad (2.14)$$

Si le i -ème étage est atteint, tous les étages précédents ont rejeté, donc $N_j < D_j$ pour $j = 1, \dots, i - 1$. On peut donc remplacer $\alpha_j = N_j/D_j$ dans le dénominateur, ce qui donne la récurrence :

$$D_i = q_i(y_i | x, \dots, y_{i-1}) (D_{i-1} - N_{i-1}), \quad (2.15)$$

initialisée par $D_1 = \pi(x) q_1(y_1 | x)$. Cette récurrence est un apport computationnel central de MIRA (2001) : elle permet de calculer α_i en $O(1)$ par étage supplémentaire, en stockant simplement (D_{i-1}, N_{i-1}) d'un étage à l'autre.

Algorithme 2 : Rejet retardé à m étages

Entrée : État courant x , densité cible non normalisée $\tilde{\pi}$, propositions $q_1, \dots, q_m$

Sortie : Nouvel état x'

```

1 Calculer  $\tilde{\pi}(x)$ ;
2 Simuler  $y_1 \sim q_1(\cdot | x)$ ;
3  $D_1 \leftarrow \tilde{\pi}(x) q_1(y_1 | x)$ ;
4 for  $i = 1, \dots, m$  do
5   if  $i > 1$  then
6     Simuler  $y_i \sim q_i(\cdot | x, y_1, \dots, y_{i-1})$ ;
7      $D_i \leftarrow q_i(y_i | x, \dots, y_{i-1}) (D_{i-1} - N_{i-1})$ ;
8   Calculer  $\tilde{\pi}(y_i)$ ;
9   Calculer  $N_i \leftarrow \tilde{\pi}(y_i) q_1(y_{i-1} | y_i) \cdots q_i(x | y_i, \dots, y_1) \prod_{j=1}^{i-1} [1 - \alpha_j(y_i, \dots, y_{i-j})]$ ;
10   $\alpha_i \leftarrow 1 \wedge N_i/D_i$ ;
11  Simuler  $u \sim \mathcal{U}(0, 1)$ ;
12  if  $u \leq \alpha_i$  then
13    return  $x' \leftarrow y_i$ ;
14 return  $x' \leftarrow x$  // rejet à tous les étages
```

Remarque 2.3.2. Puisque le bilan détaillé est satisfait séparément à chaque étage, le processus peut être interrompu à tout moment sans compromettre la correction de l'algorithme. En particulier, on peut décider a priori de tenter au plus m étages.

Le DR améliore MH au sens de Peskun

Théorème 2.3.3 (TIERNEY et MIRA (1999)). Notons P_{MH} le noyau de transition de l'algorithme de Metropolis–Hastings et P_{DR} celui de l'algorithme à rejet retardé utilisant les mêmes propositions $q_1, \dots, q_m$. Alors P_{DR} domine P_{MH} au sens de Peskun : pour tout $x \neq y$:

$$P_{\text{DR}}(x, \{y\}) \geq P_{\text{MH}}(x, \{y\}).$$

En conséquence, pour toute fonction f de variance finie sous π :

$$\sigma_{f,\text{DR}}^2 \leq \sigma_{f,\text{MH}}^2.$$

Esquisse de preuve. Le noyau P_{DR} place plus de masse hors de la diagonale que P_{MH} : là où MH resterait en x après un rejet, DR tente de se déplacer via les étages supplémentaires. Formellement, pour $x \neq y$, la probabilité de transition de x vers y sous DR est :

$$P_{\text{DR}}(x, \{y\}) = \underbrace{q_1(y | x) \alpha_1(x, y)}_{\text{étage 1}} + \underbrace{\int q_1(y_1 | x) [1 - \alpha_1(x, y_1)] q_2(y | x, y_1) \alpha_2(x, y_1, y) dy_1 + \dots}_{\text{étage 2}}$$

Le premier terme est exactement $P_{\text{MH}}(x, \{y\})$, et tous les termes supplémentaires sont positifs. Donc $P_{\text{DR}}(x, \{y\}) \geq P_{\text{MH}}(x, \{y\})$, ce qui établit la domination au sens de Peskun. La supériorité en variance asymptotique découle alors de la définition 2.3.1. $\square$

Remarque 2.3.4. La supériorité de DR sur MH est uniforme sur toutes les fonctions f de variance finie : DR ne fait jamais pire que MH, quel que soit l'estimateur considéré. Ce résultat est fort mais ne dit rien sur la vitesse de convergence vers la stationnarité : les deux objectifs (variance asymptotique et vitesse de convergence) conduisent à des notions d'optimalité différentes.

2.3.2 Metropolis adaptatif

Motivation

L'efficacité de MH dépend crucialement du choix de la distribution de proposition q . En pratique, ce choix est délicat : une proposition trop étroite génère des candidats proches de l'état courant, la chaîne avance à petits pas et explore lentement $\mathcal{X}$; une proposition trop dispersée génère des candidats dans des régions de faible densité, le taux d'acceptation s'effondre et la chaîne reste sur place. Dans les deux cas, la variance asymptotique σ_f^2 augmente.

La calibration optimale de q requiert une connaissance préalable de la forme de π — sa covariance, ses directions d'étirement, ... — qui est précisément ce qu'on cherche à estimer. Cette circularité motive les *stratégies adaptatives* : plutôt que de fixer q une fois pour toutes avant de lancer la chaîne, on l'ajuste *en ligne*, en exploitant les informations accumulées au fil des itérations.

L'algorithme de *Metropolis adaptatif* (*Adaptive Metropolis*, AM), introduit par HAARIO, SAKSMAN et TAMMINEN (2001), repose sur une idée simple : utiliser la covariance empirique des états déjà visités pour calibrer automatiquement une distribution de proposition gaussienne.

L'algorithme

On utilise une proposition gaussienne centrée à l'état courant :

$$q_n(\cdot | x^{(t)}) \sim \mathcal{N}(x^{(t)}, C_n),$$

où C_n est une matrice de covariance mise à jour à chaque itération. Après une période initiale de n_0 itérations sans adaptation, on définit :

$$C_n = \begin{cases} C_0 & n \leq n_0, \\ s_d \text{Cov}(x^{(0)}, \dots, x^{(n-1)}) + s_d \varepsilon I_d & n > n_0, \end{cases} \quad (2.16)$$

où C_0 est une covariance initiale choisie a priori, $\varepsilon > 0$ est une constante de régularisation garantissant que C_n reste définie positive, I_d est la matrice identité de dimension d , et $s_d = 2.4^2/d$ est un facteur de mise à l'échelle optimal au sens de GELMAN, ROBERTS et GILKS (1996) : pour une cible gaussienne en dimension d , ce choix maximise l'efficacité du mélange en visant un taux d'acceptation idéal, d'environ 23.4 %.

Mise à jour de C_n . Un calcul direct de $\text{Cov}(x^{(0)}, \dots, x^{(n-1)})$ nécessiterait de stocker toute la trajectoire et coûterait $O(nd^2)$ opérations à chaque pas. Nous démontrons ici un résultat de (MIRA 2001) qui permet une mise à jour computationnellement efficace de C_n .

$$C_{n+1} = \frac{n-1}{n} C_n + \frac{s_d}{n} \left(n \bar{x}_{n-1} \bar{x}_{n-1}^T - (n+1) \bar{x}_n \bar{x}_n^T + x^{(n)} x^{(n)T} + \varepsilon I_d \right). \quad (2.17)$$

On note, pour alléger :

$$\text{Cov}_n := \text{Cov}(x^{(0)}, \dots, x^{(n-1)}) = \frac{1}{n-1} \sum_{t=0}^{n-1} (x^{(t)} - \bar{x}_{n-1})(x^{(t)} - \bar{x}_{n-1})^T,$$

de sorte que $C_n = s_d \text{Cov}_n + s_d \varepsilon I_d$ pour $n > n_0$. Il suffit donc de dériver la récurrence sur Cov_n .

Forme développée de la covariance empirique.

$$\text{Cov}_n = \frac{1}{n-1} \left(\sum_{t=0}^{n-1} x^{(t)} x^{(t)T} - n \bar{x}_{n-1} \bar{x}_{n-1}^T \right). \quad (2.18)$$

Démonstration. On développe le produit :

$$\sum_{t=0}^{n-1} (x^{(t)} - \bar{x}_{n-1})(x^{(t)} - \bar{x}_{n-1})^T = \sum_{t=0}^{n-1} x^{(t)} x^{(t)T} - \sum_{t=0}^{n-1} x^{(t)} \bar{x}_{n-1}^T - \sum_{t=0}^{n-1} \bar{x}_{n-1} x^{(t)T} + \sum_{t=0}^{n-1} \bar{x}_{n-1} \bar{x}_{n-1}^T.$$

Puisque $\sum_{t=0}^{n-1} x^{(t)} = n \bar{x}_{n-1}$, les trois derniers termes donnent :

$$-n \bar{x}_{n-1} \bar{x}_{n-1}^T - n \bar{x}_{n-1} \bar{x}_{n-1}^T + n \bar{x}_{n-1} \bar{x}_{n-1}^T = -n \bar{x}_{n-1} \bar{x}_{n-1}^T,$$

ce qui établit (2.18). $\square$

Récurrence sur Cov_n . On veut exprimer Cov_{n+1} en fonction de Cov_n et du nouveau point $x^{(n)}$.

Par (2.18) appliquée à $n+1$ points :

$$n \text{Cov}_{n+1} = \sum_{t=0}^n x^{(t)} x^{(t)T} - (n+1) \bar{x}_n \bar{x}_n^T. \quad (2.19)$$

On extrait la contribution du nouveau point : $\sum_{t=0}^n x^{(t)} x^{(t)T} = \sum_{t=0}^{n-1} x^{(t)} x^{(t)T} + x^{(n)} x^{(n)T}$. En utilisant (2.18) pour exprimer $\sum_{t=0}^{n-1} x^{(t)} x^{(t)T} = (n-1) \text{Cov}_n + n \bar{x}_{n-1} \bar{x}_{n-1}^T$, on obtient :

$$n \text{Cov}_{n+1} = (n-1) \text{Cov}_n + n \bar{x}_{n-1} \bar{x}_{n-1}^T + x^{(n)} x^{(n)T} - (n+1) \bar{x}_n \bar{x}_n^T.$$

En divisant par n :

$$\text{Cov}_{n+1} = \frac{n-1}{n} \text{Cov}_n + \frac{1}{n} \left(n \bar{x}_{n-1} \bar{x}_{n-1}^T - (n+1) \bar{x}_n \bar{x}_n^T + x^{(n)} x^{(n)T} \right). \quad (2.20)$$

Récurrence sur C_n . On multiplie (2.20) par s_d et on ajoute $s_d \varepsilon I_d$ des deux côtés :

$$s_d \text{Cov}_{n+1} + s_d \varepsilon I_d = \frac{n-1}{n} s_d \text{Cov}_n + \frac{s_d}{n} \left(n \bar{x}_{n-1} \bar{x}_{n-1}^T - (n+1) \bar{x}_n \bar{x}_n^T + x^{(n)} x^{(n)T} \right) + s_d \varepsilon I_d.$$

Le membre gauche est C_{n+1} . Pour le membre droit, on reconnaît $\frac{n-1}{n} C_n$ en absorbant le terme résiduel en ε :

$$\frac{n-1}{n} C_n = \frac{n-1}{n} (s_d \text{Cov}_n + s_d \varepsilon I_d) = \frac{n-1}{n} s_d \text{Cov}_n + \frac{n-1}{n} s_d \varepsilon I_d,$$

ce qui laisse un résidu $s_d \varepsilon I_d - \frac{n-1}{n} s_d \varepsilon I_d = \frac{s_d \varepsilon}{n} I_d$ qui se combine avec le terme $\frac{s_d \varepsilon}{n} I_d$ restant pour donner :

$$C_{n+1} = \frac{n-1}{n} C_n + \frac{s_d}{n} \left(n \bar{x}_{n-1} \bar{x}_{n-1}^T - (n+1) \bar{x}_n \bar{x}_n^T + x^{(n)} x^{(n)T} + \varepsilon I_d \right). \quad (2.21)$$

où $\bar{x}_n = \frac{1}{n+1} \sum_{t=0}^n x^{(t)}$ est la moyenne empirique courante, qui satisfait elle-même la récurrence $\bar{x}_n = \frac{n \bar{x}_{n-1} + x^{(n)}}{n+1}$. La mise à jour ne requiert donc que de maintenir en mémoire C_n , $\bar{x}_{n-1}$ et $x^{(n)}$, soit un coût de $O(d^2)$ par pas, indépendamment de n .

Algorithme 3 : Metropolis adaptatif (AM)

Entrée : État initial $x^{(0)}$, covariance initiale C_0 , période de chauffe n_0 , densité cible non normalisée $\tilde{\pi}$, paramètres s_d, ε

Sortie : Trajectoire $\{x^{(t)}\}_{t=0}^N$

```

1  $\bar{x}_0 \leftarrow x^{(0)}, \quad \tilde{\pi}_{\text{cur}} \leftarrow \tilde{\pi}(x^{(0)});$ 
2 for  $t = 0, 1, \dots, N-1$  do
3   if  $t \leq n_0$  then
4      $C \leftarrow C_0;$ 
5   else
6     Mettre à jour  $C \leftarrow C_t$  via (2.17);
7   Simuler  $y \sim \mathcal{N}(x^{(t)}, C);$ 
8   Calculer  $\tilde{\pi}_{\text{prop}} \leftarrow \tilde{\pi}(y);$ 
9   Calculer  $\rho \leftarrow 1 \wedge \frac{\tilde{\pi}_{\text{prop}}}{\tilde{\pi}_{\text{cur}}};$ 
10  Simuler  $u \sim \mathcal{U}(0, 1);$ 
11  if  $u \leq \rho$  then
12     $x^{(t+1)} \leftarrow y;$ 
13     $\tilde{\pi}_{\text{cur}} \leftarrow \tilde{\pi}_{\text{prop}};$ 
14  else
15     $x^{(t+1)} \leftarrow x^{(t)};$ 
16  Mettre à jour  $\bar{x}_{t+1} \leftarrow \frac{t \bar{x}_t + x^{(t+1)}}{t+1};$ 
```

2.3.3 DRAM : Delayed Rejection Adaptive Metropolis

Les sections précédentes ont introduit deux façons distinctes d'améliorer l'algorithme MH :

- le *rejet retardé* (DR) améliore l'efficacité des estimateurs au sens de Peskun en réduisant le nombre de fois où la chaîne reste sur place. C'est une adaptation *locale* et *temporaire* : elle opère à l'intérieur d'un seul pas de temps, en utilisant l'information des candidats rejetés dans ce pas, sans modifier la proposition aux itérations suivantes ;
- le *Metropolis adaptatif* (AM) améliore le calibrage de la proposition en apprenant sa covariance en ligne. C'est une adaptation *globale* et *persistante* : elle utilise tout l'historique de la chaîne et modifie la proposition à chaque itération.

Ces deux stratégies sont *complémentaires* et remédient à des limitations symétriques. AM récu-père bien lorsque la variance initiale est trop petite, mais reste bloqué lorsque la variance est trop grande : presque aucun candidat n'est alors accepté, la chaîne ne bouge pas et l'adaptation ne peut pas démarrer. DR fournit un remède naturel à ce problème : en réduisant la variance de la proposition aux étages supérieurs, il garantit qu'au moins quelques candidats sont acceptés, ce qui permet à AM de démarrer. Réciproquement, AM améliore progressivement la proposition du premier étage de DR, qui bénéficie ainsi d'un calibrage de mieux en mieux adapté à la forme de π .

HAARIO, LAINE et al. (2006) proposent de combiner les deux stratégies dans un algorithme unique, appelé DRAM (*Delayed Rejection Adaptive Metropolis*), et démontrent l'ergodicité du processus non-markovien résultant (l'adaptation se fait sur la base de tout l'historique de la chaîne, donc, brise la propriété de Markov).

L'algorithme DRAM

- **Premier étage.** La proposition q_1 est adaptée comme dans AM : sa covariance C_n^1 est calculée à partir de la covariance empirique des états acceptés jusqu'à l'instant n , quel que soit l'étage auquel ils ont été acceptés.
- **Étages supérieurs.** La covariance du i -ème étage ($i \geq 2$) est une version mise à l'échelle de la première :

$$C_n^i = \gamma_i C_n^1,$$

où $\gamma_i > 0$ est un facteur d'échelle fixe. On choisit typiquement $\gamma_i < 1$ pour $i \geq 2$, de façon à proposer des candidats plus proches de l'état courant aux étages supérieurs, conformément à la stratégie dite de *premier audacieux, second prudent* discutée à la section 2.3.1.

Remarque 2.3.5. Le choix de mettre à jour C_n^1 à partir de tous les points acceptés, quel que soit l'étage d'acceptation, est délibéré : il garantit que l'adaptation exploite toute l'information disponible sur la forme de π , sans distinguer les points acceptés au premier étage de ceux acceptés aux étages supérieurs.

Ergodicité de DRAM

DRAM hérite des difficultés théoriques des deux algorithmes qu'il combine : comme AM, il est non-markovien ; comme DR, son noyau de transition est plus complexe qu'un simple MH. HAARIO, LAINE et al. (2006) établissent néanmoins son ergodicité par une preuve qui suit exactement la même structure que celle de AM (HAARIO, SAKSMAN et TAMMINEN 2001).

Théorème 2.3.6 (Ergodicité de DRAM, HAARIO, LAINE et al. (2006)). Soit π une densité bornée supportée sur un ensemble borné $\mathcal{X} \subset \mathbb{R}^d$. Pour toute fonction $f : \mathcal{X} \rightarrow \mathbb{R}$ bornée et mesurable :

$$\frac{1}{N} \sum_{t=1}^N f(x^{(t)}) \xrightarrow{N \rightarrow \infty} \mathbb{E}_\pi[f] \quad p.s.$$

Esquisse de preuve.

Formalisation. DRAM est formalisé comme une suite de noyaux généralisés :

$$K_n(x^{(0)}, \dots, x^{(n-1)}; A) = Q_{C_n^1, \gamma C_n^1}(x^{(n-1)}; A),$$

où Q_{C^1, C^2} est le noyau DR à deux étages gaussien avec covariances fixées C^1 et C^2 . Pour des covariances fixées, Q_{C^1, C^2} est un noyau markovien classique qui préserve π exactement (MIRA 2001). La dépendance en l'historique est entièrement capturée par C_n^1 : une fois gelée, la transition est celle d'un DR markovien standard. On définit le *noyau gelé* $K_{n, \tilde{y}_{n-1}}(x; A) := K_n(\tilde{y}_{n-1}, x; A)$, qui est un noyau markovien ordinaire pour tout historique fixé $\tilde{y}_{n-1}$.

Résultats préliminaires. Sous l'hypothèse que le support $\mathcal{X}$ de π est borné et que $\varepsilon > 0$, les covariances sont uniformément encadrées :

$$s_d \varepsilon I_d \leq C_n^1 \leq a_2 I_d \quad \forall n,$$

et varient lentement : $\|C_{n+1}^1 - C_n^1\| = O(1/n)$. HAARIO, LAINE et al. (2006) établissent de plus que Q_{C^1, C^2} est Lipschitz en les covariances : il existe $L > 0$ tel que pour tout $x \in \mathcal{X}$ et tout borélien A :

$$|Q_{C^1, C^2}(x, A) - Q_{\tilde{C}^1, \tilde{C}^2}(x, A)| \leq L (\|C^1 - \tilde{C}^1\| + \|C^2 - \tilde{C}^2\|).$$

Ces deux résultats combinés impliquent que le noyau de DRAM varie de $O(1/n)$ d'un pas au suivant.

Vérification des trois conditions. On vérifie les trois conditions du théorème d'ergodicité général de HAARIO, SAKSMAN et TAMMINEN (2001) pour processus adaptatifs non-markoviens :

- (i) **Ergodicité uniforme.** L'encadrement des covariances garantit que la densité gaussienne est uniformément minorée sur $\mathcal{X}$: il existe $c > 0$ tel que $K_{n, \tilde{y}_{n-1}}(x, A) \geq c \pi(A)$ pour tout x et tout A . C'est la condition de Doeblin, qui implique l'ergodicité uniforme avec $k_0 = 1$.
- (ii) **Stationnarité approchée.** En notant $C^* = C_{n-1}^1$, la propriété de Lipschitz et le contrôle $\|C_n^1 - C^*\| \leq a/n$ donnent $\|K_{n, \tilde{y}_{n-1}} - Q_{C^*, \gamma C^*}\|_{TV} \leq c_0/n$. Puisque $\pi Q_{C^*, \gamma C^*} = \pi$ exactement (MIRA 2001), on conclut $\|\pi K_{n, \tilde{y}_{n-1}} - \pi\|_{TV} \leq c_0/n$.
- (iii) **Stabilité temporelle.** Entre les instants n et $n+k$, la covariance change de $O(k/n)$, et la propriété de Lipschitz donne $\|K_{n, \tilde{y}_{n-1}} - K_{n+k, \tilde{y}_{n+k-1}}\|_{TV} \leq c_1 k/n$.

Les trois conditions étant satisfaites, le théorème d'ergodicité général de HAARIO, SAKSMAN et TAMMINEN (2001) conclut quant à l'ergodicité du processus DRAM. $\square$

2.4 Méthodes à gradient

Algorithme 4 : DRAM à deux étages

Entrée : État initial $x^{(0)}$, covariance initiale C_0 , facteur d'échelle γ , période de chauffe n_0 , densité cible non normalisée $\tilde{\pi}$, paramètres s_d, ε

Sortie : Trajectoire $\{x^{(t)}\}_{t=0}^N$

```

1  $\bar{x}_0 \leftarrow x^{(0)}, \quad C^1 \leftarrow C_0, \quad C^2 \leftarrow \gamma C_0, \quad \tilde{\pi}_{\text{cur}} \leftarrow \tilde{\pi}(x^{(0)});$ 
2 for  $t = 0, 1, \dots, N - 1$  do
    /* -- Premier étage -- */
3     Simuler  $y_1 \sim \mathcal{N}(x^{(t)}, C^1);$ 
4     Calculer  $\tilde{\pi}_1 \leftarrow \tilde{\pi}(y_1);$ 
5     Calculer  $\alpha_1 \leftarrow 1 \wedge \frac{\tilde{\pi}_1}{\tilde{\pi}_{\text{cur}}};$ 
6     Simuler  $u_1 \sim \mathcal{U}(0, 1);$ 
7     if  $u_1 \leq \alpha_1$  then
8          $x^{(t+1)} \leftarrow y_1, \quad \tilde{\pi}_{\text{cur}} \leftarrow \tilde{\pi}_1;$ 
9     else
10        /* -- Deuxième étage (rejet retardé) -- */
11        Simuler  $y_2 \sim \mathcal{N}(x^{(t)}, C^2);$ 
12        Calculer  $\tilde{\pi}_2 \leftarrow \tilde{\pi}(y_2);$ 
13        Calculer  $\alpha_2 \leftarrow 1 \wedge \frac{\tilde{\pi}_2 q_{C^1}(y_2, y_1) [1 - \alpha_1(y_2, y_1)]}{\tilde{\pi}_{\text{cur}} q_{C^1}(x^{(t)}, y_1) [1 - \alpha_1(x^{(t)}, y_1)]};$ 
14        Simuler  $u_2 \sim \mathcal{U}(0, 1);$ 
15        if  $u_2 \leq \alpha_2$  then
16             $x^{(t+1)} \leftarrow y_2, \quad \tilde{\pi}_{\text{cur}} \leftarrow \tilde{\pi}_2;$ 
17        else
18             $x^{(t+1)} \leftarrow x^{(t)};$ 
19        /* -- Mise à jour de la covariance (AM) -- */
20        if  $t > n_0$  then
21            Mettre à jour  $C^1 \leftarrow C_{t+1}^1$  via (2.17);
22             $C^2 \leftarrow \gamma C^1;$ 
23        Mettre à jour  $\bar{x}_{t+1} \leftarrow \frac{t \bar{x}_t + x^{(t+1)}}{t + 1};$ 

```

Chapitre 3

Diagnostics de convergence

Le théorème ergodique (section 2.1.3) garantit la convergence asymptotique de la chaîne vers π , mais ne fournit aucun critère pratique pour déterminer si la loi des $(X_n)_n$ (au moins à partir d'un instant n_0) est suffisamment proche de π pour que les estimateurs soient fiables. En l'absence de méthode permettant de *certifier* la convergence, les diagnostics présentés ici constituent des *conditions nécessaires* : ils permettent de détecter une absence de convergence, mais non de la garantir (COWLES et CARLIN 1996).

3.1 Diagnostic de Geweke

Le théorème ergodique garantit la convergence asymptotique de la chaîne, mais ne fournit pas de critère pratique pour déterminer à partir de quelle itération les estimateurs sont fiables. Les premiers éléments de la chaîne sont fortement influencés par l'état initial — c'est la *phase de chauffe* (*burn-in*) — et leur suppression est nécessaire avant toute inférence. Le diagnostic de GEWEKE (1992) fournit un test statistique formel pour valider le choix de l'itération n_0 à partir de laquelle la chaîne est effectivement entrée dans sa stationnarité et échantillonne effectivement la distribution cible.

Principe. Soit $\theta = (\theta_1, \dots, \theta_d)$ et g une fonction d'intérêt. Si la chaîne a atteint le régime stationnaire, les moyennes empiriques de $g(\theta)$ calculées sur le début de la chaîne post burn-in et la fin de cette même chaîne doivent estimer la même quantité $\mathbb{E}_\pi[g(\theta)]$. Cela est vrai en particulier pour $g = \text{Id}$: on s'intéresse donc en pratique à la convergence de la moyenne empirique de chaque composante θ_j vers $\mathbb{E}_\pi[\theta_j]$, pour $j = 1, \dots, d$.

On définit deux segments disjoints de la chaîne de longueur N :

$$A = \{\theta^{(1)}, \dots, \theta^{(n_A)}\}, \quad B = \{\theta^{(N-n_B+1)}, \dots, \theta^{(N)}\}, \quad (3.1)$$

avec $n_A = \lfloor \alpha N \rfloor$, $n_B = \lfloor \beta N \rfloor$, et $\alpha + \beta < 1$. Les valeurs canoniques $\alpha = 0,1$ et $\beta = 0,5$ sont recommandées par GEWEKE (1992). Pour chaque composante $j = 1, \dots, d$, on note :

$$\bar{\theta}_{A,j} = \frac{1}{n_A} \sum_{t=1}^{n_A} \theta_j^{(t)}, \quad \bar{\theta}_{B,j} = \frac{1}{n_B} \sum_{t=N-n_B+1}^N \theta_j^{(t)}$$

les moyennes empiriques de la j -ème composante sur chaque segment. Sous l'hypothèse nulle H_0 de stationnarité :

$$\mathbb{E}_{H_0}[\bar{\theta}_{A,j} - \bar{\theta}_{B,j}] = 0 \quad \forall j = 1, \dots, d. \quad (3.2)$$

Statistique de test. Les $\theta_j^{(t)}$ ne sont pas indépendants : les corrélations temporelles de la chaîne gonflent la variance de la moyenne empirique. Par le TCL pour chaînes de Markov (théorème 2.1.14), $\bar{\theta}_{A,j}$ et $\bar{\theta}_{B,j}$ sont asymptotiquement gaussiens, de variances respectives $S_{A,j}^2/n_A$ et $S_{B,j}^2/n_B$, où :

$$S_j^2 = \text{Var}_\pi(\theta_j) + 2 \sum_{k=1}^{+\infty} \text{Cov}_\pi(\theta_j^{(0)}, \theta_j^{(k)}) \quad (3.3)$$

est la variance spectrale à fréquence zéro de la j -ème composante. Puisque les segments A et B sont disjoints et suffisamment éloignés, $\bar{\theta}_{A,j}$ et $\bar{\theta}_{B,j}$ sont asymptotiquement indépendants. La statistique de Geweke pour la composante j est alors :

$$z_{\text{Gewe},j} = \frac{\bar{\theta}_{A,j} - \bar{\theta}_{B,j}}{\sqrt{\frac{\hat{S}_{A,j}^2}{n_A} + \frac{\hat{S}_{B,j}^2}{n_B}}}, \quad (3.4)$$

où $\hat{S}_{A,j}^2$ et $\hat{S}_{B,j}^2$ sont des estimateurs de S_j^2 calculés séparément sur chaque segment par méthode de densité spectrale. Sous H_0 :

$$z_{\text{Gewe},j} \xrightarrow{d} \mathcal{N}(0,1) \quad \forall j = 1, \dots, d.$$

Règle de décision. On rejette H_0 au niveau α si $|z_{\text{Gewe},j}| > \Phi^{-1}(1 - \frac{\alpha}{2})$ pour au moins une composante j . Φ est la fonction de répartition de la loi normale centrée réduite. Le burn-in est jugé suffisant si $|z_{\text{Gewe},j}| \leq 1,96$ pour toutes les composantes $j = 1, \dots, d$.

3.2 Diagnostic de Gelman–Rubin

Le diagnostic de GELMAN et RUBIN (1992) repose sur l'idée que plusieurs chaînes initialisées à des points distincts de l'espace Θ doivent, une fois convergées, être statistiquement indiscernables. Si la variance *entre* les chaînes reste significativement supérieure à la variance *intra*-chaîne, c'est le signe que certaines chaînes n'ont pas encore exploré la totalité du support de π .

Mise en place. On simule M chaînes indépendantes, chacune de longueur $n_0 + N$, et l'on ne conserve que les N dernières itérations (après burn-in). Pour une composante scalaire θ_j fixée, on note $\theta_{i,m}$ la i -ème valeur de la m -ème chaîne ($i = 1, \dots, N$, $m = 1, \dots, M$), et l'on définit les moyennes :

$$\bar{\theta}_{\cdot,m} = \frac{1}{N} \sum_{i=1}^N \theta_{i,m}, \quad \bar{\theta} = \frac{1}{M} \sum_{m=1}^M \bar{\theta}_{\cdot,m}. \quad (3.5)$$

Décomposition de la variance. On calcule la variance *inter*-chaînes B et la variance *intra*-chaîne moyenne W :

$$B = \frac{N}{M-1} \sum_{m=1}^M (\bar{\theta}_{\cdot,m} - \bar{\theta})^2, \quad W = \frac{1}{M} \sum_{m=1}^M s_m^2, \quad \text{avec} \quad s_m^2 = \frac{1}{N-1} \sum_{i=1}^N (\theta_{i,m} - \bar{\theta}_{\cdot,m})^2. \quad (3.6)$$

B/N et W sont deux estimateurs de $\text{Var}_\pi(\theta_j)$ en régime stationnaire, construits à partir de sources d'information différentes. Pour N fini :

- **W sous-estime $\text{Var}_\pi(\theta_j)$** car chaque chaîne individuelle n'a pas encore exploré la totalité du support de π : sa variance empirique ne reflète que la dispersion locale observée, pas la dispersion globale de π ;
- **B/N surestime $\text{Var}_\pi(\theta_j)$** car les chaînes, initialisées de façon sur-dispersée, sont encore trop éloignées les unes des autres : leurs moyennes $\bar{\theta}_{.,m}$ sont plus dispersées que ne le serait θ_j sous π .

L'idée de BROOKS et GELMAN (1998) est de combiner W et B/N de façon à obtenir un estimateur *conservateur* de $\text{Var}_\pi(\theta_j)$: légèrement surestimé pour N fini, mais convergeant vers la vraie valeur quand $N \rightarrow \infty$. On écrit :

$$\hat{V} = \underbrace{\frac{N-1}{N} W}_{W \text{ contracté}} + \underbrace{\frac{M+1}{MN} B}_{B/N \text{ augmenté}}. \quad (3.7)$$

Le premier terme contracte W par le facteur $\frac{N-1}{N} < 1$, compensant partiellement sa sous-estimation. Le second terme augmente B/N par le facteur $\frac{M+1}{M} > 1$, qui tient compte de l'incertitude d'estimation de la moyenne globale $\bar{\theta}$: celle-ci étant estimée à partir de M chaînes, elle est, elle-même, une quantité aléatoire.

Pour N fini, $\hat{V}$ surestime $\text{Var}_\pi(\theta_j)$ car $B > W$ tant que les chaînes explorent des régions distinctes. Sous hypothèse de convergence, quand $N \rightarrow \infty$, $B/N \rightarrow 0$ et $W \rightarrow \text{Var}_\pi(\theta_j)$, de sorte que $\hat{V} \rightarrow \text{Var}_\pi(\theta_j)$.

Ces propriétés motivent la définition du *R hat*, aussi appelé *facteur de réduction d'échelle potentielle* (Potential Scale Reduction Factor, PSRF) :

$$\hat{R} = \sqrt{\frac{\hat{V}}{W}}. \quad (3.8)$$

Pour N fini, $\hat{R} > 1$ car :

$$\hat{V} - W = \frac{N-1}{N} W + \frac{M+1}{MN} B - W = \frac{(M+1)B - W}{MN} > 0$$

dès que $B > W/(M+1)$, ce qui est le cas tant que les chaînes n'ont pas atteint leur régime stationnaire et continuent d'explorer des régions distinctes de Θ . Sous hypothèse de convergence, $\hat{R} \rightarrow 1$ quand $N \rightarrow \infty$. Un écart significatif de $\hat{R}$ par rapport à 1 indique que la variance inter-chaînes est encore trop grande relativement à la variance intra-chaîne : certaines régions de π n'ont pas été explorées. En pratique, on considère que les chaînes ont convergé lorsque $\hat{R} < 1,1$ pour toutes les composantes de θ (GELMAN et RUBIN 1992).

Remarque 3.2.1. *Le diagnostic de Gelman–Rubin repose sur l'hypothèse que la distribution initiale des chaînes est sur-dispersée par rapport à π . Si toutes les chaînes sont initialisées dans la même région de l'espace, le critère $\hat{R} \approx 1$ peut être satisfait même en l'absence de convergence globale. Il est donc recommandé d'initialiser les chaînes de manière dispersée, par exemple en tirant les points de départ depuis le prior $\pi(\theta)$.*

3.3 Diagnostic de Raftery – Lewis

Le diagnostic de RAFTERY et LEWIS (1992) poursuit un objectif différent des deux précédents : plutôt que de tester la stationnarité de la chaîne, il fournit des recommandations *quantitatives* sur le nombre m^* d'itérations de burn-in et le nombre n^* d'itérations de calcul nécessaires pour estimer un quantile de la loi cible avec une précision et une probabilité de couverture fixées à l'avance.

Mise en place. Pour une composante θ_j et un niveau $q \in (0, 1)$ fixé, on s'intéresse à l'estimation du quantile u défini par :

$$\mathbb{P}(\theta_j < u \mid \mathbf{x}) = q.$$

On binarise la chaîne en introduisant les indicatrices :

$$Z_t = \mathbf{1}_{[\theta_j^{(t)} < u]}, \quad t = 1, 2, \dots \quad (3.9)$$

Estimer u revient à estimer $q = \mathbb{P}(\theta_j < u \mid \mathbf{x})$, c'est-à-dire la proportion de 1 dans la suite (Z_t) . Puisque les $\theta_j^{(t)}$ sont corrélés, les Z_t le sont aussi : si $\theta_j^{(t)}$ est en dessous de u , le suivant a tendance à l'être également.

Pour réduire cette dépendance, on considère la *sous-chaîne* espacée de k itérations :

$$Z_t^{(k)} = Z_{1+(t-1)k}, \quad t = 1, 2, \dots \quad (3.10)$$

Choix de k . Pour k suffisamment grand, la sous-chaîne $(Z_t^{(k)})$ est bien approchée par une chaîne de Markov d'ordre 1 à deux états $\{0, 1\}$: la loi de $Z_{t+1}^{(k)}$ ne dépend que de $Z_t^{(k)}$ et non des états antérieurs. Sa matrice de transition est :

$$T_k = \begin{pmatrix} 1 - \alpha & \alpha \\ \beta & 1 - \beta \end{pmatrix}, \quad (3.11)$$

où $\alpha = \mathbb{P}(Z_{t+1}^{(k)} = 1 \mid Z_t^{(k)} = 0)$ et $\beta = \mathbb{P}(Z_{t+1}^{(k)} = 0 \mid Z_t^{(k)} = 1)$ sont estimés sur une chaîne pilote.

Pour déterminer k , on teste si le modèle d'ordre 1 est statistiquement acceptable en le comparant au modèle d'ordre 2. Ces deux modèles se distinguent par leur structure de dépendance :

- **Modèle d'ordre 1 :** la probabilité de $Z_{t+1}^{(k)}$ ne dépend que de $Z_t^{(k)}$. Il est entièrement caractérisé par *deux* paramètres libres : α et β .
- **Modèle d'ordre 2 :** la probabilité de $Z_{t+1}^{(k)}$ dépend de $Z_t^{(k)}$ et de $Z_{t-1}^{(k)}$. Il requiert *quatre* paramètres libres, un pour chaque paire $(Z_{t-1}^{(k)}, Z_t^{(k)}) \in \{0, 1\}^2$.

Le modèle d'ordre 1 est un cas particulier contraint du modèle d'ordre 2 : les deux modèles sont *emboîtés*, ce qui permet d'appliquer le test du rapport de vraisemblance. On note $\hat{L}_1$ et $\hat{L}_2$ les vraisemblances maximisées sous chaque modèle. La statistique de test est :

$$T_{\text{LRT}} = -2 \log \Lambda, \quad \text{où } \Lambda = \frac{\hat{L}_1}{\hat{L}_2}. \quad (3.12)$$

Les vraisemblances $\hat{L}_1$ et $\hat{L}_2$ sont calculées à partir des fréquences de transition observées dans la sous-chaîne. On note :

$$n_{ij} = \#\{t : Z_t^{(k)} = i, Z_{t+1}^{(k)} = j\}, \quad i, j \in \{0, 1\},$$

les effectifs de transitions d'ordre 1, et :

$$n_{hij} = \#\{t : Z_{t-1}^{(k)} = h, Z_t^{(k)} = i, Z_{t+1}^{(k)} = j\}, \quad h, i, j \in \{0, 1\},$$

les effectifs de transitions d'ordre 2. Les estimateurs du maximum de vraisemblance sont les fréquences empiriques :

$$\hat{\alpha} = \frac{n_{01}}{n_{00} + n_{01}}, \quad \hat{\beta} = \frac{n_{10}}{n_{10} + n_{11}}, \quad \hat{p}_{hij} = \frac{n_{hij}}{n_{hi0} + n_{hi1}}.$$

Les vraisemblances maximisées s'écrivent alors :

$$\hat{L}_1 = \left(\frac{n_{00}}{n_{00} + n_{01}} \right)^{n_{00}} \left(\frac{n_{01}}{n_{00} + n_{01}} \right)^{n_{01}} \left(\frac{n_{10}}{n_{10} + n_{11}} \right)^{n_{10}} \left(\frac{n_{11}}{n_{10} + n_{11}} \right)^{n_{11}}, \quad (3.13)$$

$$\hat{L}_2 = \prod_{h,i,j \in \{0,1\}} \hat{p}_{hij}^{n_{hij}}. \quad (3.14)$$

Sous H_0 (le modèle d'ordre 1 est correct), le théorème de Wilks (WILKS 1938) garantit que T_{LRT} converge en loi vers un χ^2 dont le degré de liberté est la différence du nombre de paramètres libres entre les deux modèles :

$$T_{\text{LRT}} \xrightarrow{\mathcal{L}} \chi_{4-2}^2 = \chi_2^2.$$

On choisit le plus petit k pour lequel H_0 n'est pas rejetée au niveau 5 %, c'est-à-dire tel que $T_{\text{LRT}} \leq \chi_2^2(0,95) \approx 5,99$.

Détermination de m^* . La matrice T_k est une matrice stochastique 2×2 . Ses valeurs propres s'obtiennent en résolvant $\det(T_k - \lambda I_2) = 0$:

$$(1 - \alpha - \lambda)(1 - \beta - \lambda) - \alpha\beta = 0 \implies (1 - \lambda)[(1 - \lambda) - (\alpha + \beta)] = 0,$$

ce qui donne $\lambda_1 = 1$ (valeur propre commune à toute matrice stochastique, associée à la loi stationnaire) et $\lambda_2 = 1 - \alpha - \beta =: \lambda$. Puisque $\alpha, \beta \in (0, 1)$, on a $|\lambda| < 1$.

Par diagonalisation de T_k , la puissance l -ième s'écrit :

$$T_k^l = \underbrace{\begin{pmatrix} \pi_0 & \pi_1 \\ \pi_0 & \pi_1 \end{pmatrix}}_{\text{terme stationnaire}} + \lambda^l \underbrace{\begin{pmatrix} \pi_1 & -\pi_1 \\ -\pi_0 & \pi_0 \end{pmatrix}}_{\text{terme transitoire}}, \quad (3.15)$$

que l'on vérifie pour $l = 0$: le terme stationnaire plus le terme transitoire donne bien I_2 . Le premier terme est la matrice dont chaque ligne est la loi stationnaire (π_0, π_1) : c'est vers cette matrice que T_k^l converge. Le second terme est une correction transitoire qui décroît géométriquement en λ^l vers zéro, à vitesse d'autant plus rapide que $|\lambda| = |1 - \alpha - \beta|$ est petit.

L'écart entre la loi de $Z_l^{(k)}$ et la loi stationnaire π_i est donc :

$$\left| P(Z_l^{(k)} = i \mid Z_0^{(k)} = j) - \pi_i \right| = |\lambda|^l \cdot |c_{ji}|,$$

où c_{ji} désigne l'élément (j, i) de la matrice transitoire. En majorant $|c_{ji}|$ par sa valeur maximale sur les quatre entrées :

$$|c_{ji}| \leq \max(\pi_0, \pi_1) = \frac{\max(\alpha, \beta)}{\alpha + \beta},$$

on obtient la majoration uniforme :

$$\left| P(Z_l^{(k)} = i \mid Z_0^{(k)} = j) - \pi_i \right| \leq |\lambda|^l \cdot \frac{\max(\alpha, \beta)}{\alpha + \beta} \quad \forall i, j \in \{0, 1\}. \quad (3.16)$$

Le burn-in m^* est le plus petit entier tel que cette borne soit inférieure à ε :

$$|\lambda|^{m^*} \cdot \frac{\max(\alpha, \beta)}{\alpha + \beta} < \varepsilon.$$

En prenant le logarithme (en notant que $\log |\lambda| < 0$, ce qui inverse l'inégalité) et en prenant le plafond pour obtenir un entier :

$$m^* = \left\lceil \frac{\log \left[\frac{(\alpha + \beta) \varepsilon}{\max(\alpha, \beta)} \right]}{\log |\lambda|} \right\rceil. \quad (3.17)$$

Le nombre d'itérations de burn-in à supprimer est $n_0 = k \cdot m^*$: on multiplie par k car m^* est exprimé en pas de la sous-chaîne espacée de k itérations.

Détermination de n^* . L'estimateur de q est la moyenne empirique de la sous-chaîne :

$$\hat{q} = \frac{1}{n} \sum_{t=1}^n Z_t^{(k)}.$$

Puisque $Z_t^{(k)} = \mathbf{1}[\theta_j^{(t)} < u]$ est une fonction de l'état courant de la chaîne, le TCL pour chaînes de Markov (théorème 2.1.14) appliqué à $f = \mathbf{1}[\cdot < u]$ donne :

$$\sqrt{n}(\hat{q} - q) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma_{Z^{(k)}}^2),$$

où la variance asymptotique est :

$$\sigma_{Z^{(k)}}^2 = \text{Var}_{\pi}(Z_0^{(k)}) + 2 \sum_{l=1}^{+\infty} \text{Cov}_{\pi}(Z_0^{(k)}, Z_l^{(k)}).$$

La somme des covariances est calculable en forme close grâce à la structure markovienne de la sous-chaîne et à la formule (3.15), qui donne $\text{Cov}_{\pi}(Z_0^{(k)}, Z_l^{(k)}) = \pi_0 \pi_1 \lambda^l$. En sommant la série géométrique :

$$\nu^2 = \pi_0 \pi_1 \left(1 + 2 \sum_{l=1}^{+\infty} \lambda^l \right) = \pi_0 \pi_1 \frac{1 + \lambda}{1 - \lambda} = \frac{\alpha \beta (2 - \alpha - \beta)}{(\alpha + \beta)^3}. \quad (3.18)$$

On souhaite que $\hat{q}$ estime q à précision r avec probabilité de couverture s :

$$\mathbb{P}(|\hat{q} - q| < r) = s.$$

Par le TCL, cette condition s'écrit :

$$2 \Phi \left(\frac{r \sqrt{n^*}}{\nu} \right) - 1 = s \implies \frac{r \sqrt{n^*}}{\nu} = \Phi^{-1} \left(\frac{1+s}{2} \right),$$

d'où, en isolant n^* et en prenant le plafond :

$$n^* = \left\lceil \frac{\alpha \beta (2 - \alpha - \beta)}{(\alpha + \beta)^3} \cdot \frac{\left(\Phi^{-1} \left(\frac{1+s}{2} \right) \right)^2}{r^2} \right\rceil. \quad (3.19)$$

Le nombre total d'itérations est $N_{\text{tot}} = n_0 + k \cdot n^*$.

Les valeurs canoniques recommandées par RAFTERY et LEWIS (1992) sont $q = 0,025$, $r = 0,005$ et $s = 0,95$, ce qui correspond à estimer le quantile à 2,5 % à $\pm 0,005$ avec probabilité 0,95. Le diagnostic est appliqué séparément pour chaque composante θ_j , $j = 1, \dots, d$, et on retient :

$$N_{\text{tot}} = \max_{j=1, \dots, d} N_{\text{tot},j}$$

comme longueur totale de la chaîne.

Remarque 3.3.1. Les paramètres α , β et k sont estimés sur une chaîne pilote de longueur modérée avant de lancer la simulation principale. Le diagnostic de Raftery–Lewis est donc une méthode en deux temps : une phase exploratoire pour calibrer m^* et n^* , suivie de la simulation principale de longueur N_{tot} . BROOKS et GELMAN (1998) recommandent de tester plusieurs valeurs de u et de retenir le maximum des N_{tot} obtenus, afin de ne pas sous-estimer les besoins en itérations pour les quantiles les plus extrêmes.

3.4 Taille effective d'échantillon (ESS)

Les $\theta^{(t)}$ issus de la chaîne sont corrélés, ce qui dégrade l'efficacité de l'estimateur Monte Carlo par rapport au cas i.i.d. Pour quantifier cette dégradation, on introduit la fonction d'autocorrélation de la chaîne.

Définition 3.4.1 (Autocorrélation au lag k). Pour une chaîne stationnaire et une composante θ_j , l'autocorrélation au lag $k \geq 0$ est :

$$\rho_j(k) = \frac{\text{Cov}_\pi(\theta_j^{(0)}, \theta_j^{(k)})}{\text{Var}_\pi(\theta_j)}, \quad (3.20)$$

avec $\rho_j(0) = 1$ par définition. On définit le facteur d'autocorrélation intégrée :

$$\kappa_j = 1 + 2 \sum_{k=1}^{+\infty} \rho_j(k). \quad (3.21)$$

Remarque 3.4.2. En pratique, $\rho_j(k)$ décroît typiquement comme $\exp(-k/\tau_j)$ et la somme (3.21) converge rapidement. κ_j peut être estimé via la densité spectrale à fréquence zéro de la série $(\theta_j^{(t)})_t$ (GEWEKE 1992).

Par le théorème central limite pour chaînes de Markov (théorème 2.1.14), la variance de l'estimateur Monte Carlo de $\mathbb{E}_\pi[\theta_j]$ s'écrit :

$$\text{Var}\left(\frac{1}{N} \sum_{t=1}^N \theta_j^{(t)}\right) \approx \frac{\kappa_j}{N} \text{Var}_\pi(\theta_j). \quad (3.22)$$

La variance est donc κ_j fois plus grande que dans le cas i.i.d. — le facteur $\kappa_j \geq 1$ quantifie le surcoût dû aux corrélations temporelles de la chaîne.

Définition 3.4.3 (Taille effective d'échantillon). La taille effective d'échantillon (ESS, *Effective Sample Size*) pour la composante θ_j , sur une trajectoire de longueur N , est :

$$\text{ESS}_j = \frac{N}{\kappa_j}. \quad (3.23)$$

Elle représente le nombre d'observations i.i.d. apportant une information équivalente à la trajectoire corrélée de longueur N pour l'estimation de $\mathbb{E}_\pi[\theta_j]$.

Remarque 3.4.4. L'ESS est calculé séparément pour chaque composante $j = 1, \dots, d$. On retient :

$$\text{ESS}_{\min} = \min_{j=1, \dots, d} \text{ESS}_j$$

comme indicateur global de la qualité de la chaîne, car une seule composante mal échantillonnée suffit à invalider l'inférence.

Deuxième partie

Applications et résultats

Chapitre 4

Benchmark d'évaluation : cas jouets

Avant d'évaluer les performances des algorithmes MCMC sur des codes de calcul réels, nous définissons une suite de quatre distributions cibles de référence, choisies pour couvrir un spectre représentatif des difficultés rencontrées en échantillonnage. Chaque distribution met en défaut une propriété différente des algorithmes à proposal fixe, permettant ainsi une analyse comparative structurée.

4.1 Banane de Rosenbrock

4.1.1 Présentation

Définition 4.1.1 (Distribution de Rosenbrock). *La distribution de Rosenbrock en dimension d est définie par la densité non normalisée :*

$$\tilde{\pi}(\theta) \propto \exp\left(-\sum_{i=0}^{d-2} \left[a (\theta_{i+1} - \theta_i^2)^2 + \frac{(1 - \theta_i)^2}{b} \right]\right), \quad (4.1)$$

où $a > 0$ contrôle la courbure et $b > 0$ contrôle l'étalement. Dans nos expériences, nous utilisons $d = 2$, $a = 2$ et $b = 40$.

La distribution (4.1) tire son nom de la fonction de Rosenbrock (ROSENBROCK 1960), initialement introduite comme fonction test pour les algorithmes d'optimisation. En tant que distribution de probabilité, elle présente une masse concentrée le long d'une vallée parabolique fortement courbée dans $\mathbb{R}^2$, dont le mode se situe en $\theta^* = (2, 2)$.

La difficulté pour un algorithme MCMC à proposal gaussien isotrope $\mathcal{N}(0, \sigma^2 I)$ est que la géométrie de la distribution est fortement anisotrope et non linéaire : la direction de forte variance (le long de la vallée parabolique) et la direction de faible variance (transversale) requièrent des pas σ radicalement différents. Un proposal isotrope ne peut être adapté qu'à l'une de ces deux directions simultanément, ce qui conduit soit à une exploration lente de la vallée, soit à un taux de rejet élevé dans la direction transversale.

4.1.2 Résultats

4.2 Paysage de Rastrigin

4.2.1 Présentation

Définition 4.2.1 (Distribution de Rastrigin). *La distribution de Rastrigin en dimension d est définie par la densité non normalisée :*

$$\tilde{\pi}(\theta) \propto \exp\left(-\frac{1}{T} \left[Ad + \sum_{i=1}^d (\theta_i^2 - A \cos(2\pi\theta_i)) \right]\right), \quad (4.2)$$

où $A > 0$ contrôle l'amplitude des oscillations et $T > 0$ est un paramètre de température. Dans nos expériences, nous utilisons $d = 2$, $A = 10$ et $T = 2$.

La fonction énergie dans (4.2) est la fonction de Rastrigin standard, initialement proposée par RASTRIGIN (1974) comme benchmark d'optimisation globale. Elle possède un minimum global en $\theta^* = 0$ et un très grand nombre de minima locaux arrangés sur une grille régulière d'espacement unité, dont le nombre croît exponentiellement avec la dimension.

La *multimodalité* est la difficulté centrale : un algorithme MCMC local peut rester piégé indéfiniment dans un mode local sans jamais explorer les autres modes, même si ceux-ci ont une masse comparable. Le taux d'acceptation devient très faible car la plupart des propositions atterrissent dans des régions de faible densité entre les modes. Le paramètre de température $T = 2$ aplatit partiellement les barrières énergétiques entre modes, rendant les transitions inter-modes accessibles à un algorithme de marche aléatoire — ce qui en fait un cas limite instructif plutôt qu'un cas d'échec total.

Cette distribution représente les posteriors multimodaux rencontrés lorsque le modèle physique présente plusieurs configurations de paramètres équivalentes (symétries, dégénérescences), ou lorsque les données sont insuffisantes pour lever une ambiguïté paramétrique. Elle pourrait motiver l'utilisation de techniques de *tempering* comme le *Parallel Tempering*.

4.2.2 Résultats

4.3 Entonnoir de Neal

4.3.1 Présentation

Définition 4.3.1 (Entonnoir de Neal). *L'entonnoir de Neal en dimension d est défini par la loi jointe hiérarchique :*

$$v \sim \mathcal{N}(0, \sigma_v^2), \quad x_i | v \sim \mathcal{N}(0, e^v), \quad i = 1, \dots, d-1, \quad (4.3)$$

avec $\theta = (v, x_1, \dots, x_{d-1}) \in \mathbb{R}^d$. La log-densité non normalisée s'écrit :

$$\log \tilde{\pi}(\theta) = -\frac{v^2}{2\sigma_v^2} - \frac{(d-1)v}{2} - \frac{e^{-v}}{2} \sum_{i=1}^{d-1} x_i^2. \quad (4.4)$$

Dans nos expériences, nous utiliserons $d = 10$ et $\sigma_v = 2$. La figure 4.1 est, quant à elle, faite pour $d = 2$.

La variable v joue le rôle d'un *paramètre d'échelle global* : elle contrôle la variance de toutes les composantes x_i . Lorsque v est grand et positif, les x_i sont très dispersés (bouche de l'entonnoir); lorsque v est grand et négatif, les x_i sont concentrés près de zéro (col de l'entonnoir).

Cette distribution a été introduite par NEAL (2003) précisément pour illustrer l'échec des algorithmes MCMC à proposal fixe. Le pas optimal dans le col ($v \ll 0$, variance $e^v \approx 0$) est

radicalement différent de celui requis dans la bouche ($v \gg 0$, variance $e^v \gg 1$). Aucun σ global ne peut être simultanément adapté aux deux régimes : la chaîne explore bien l'un au détriment de l'autre, produisant une autocorrélation élevée ou une sous-représentation systématique du col.

4.3.2 Résultats

4.4 Gaussienne fortement corrélée en haute dimension

4.4.1 Présentation

Définition 4.4.1. La distribution gaussienne en dimension d est définie par :

$$\pi(\theta) = \mathcal{N}(\theta \mid \mu, \Sigma), \quad (4.5)$$

où $\mu \in \mathbb{R}^d$ est la moyenne et $\Sigma \in \mathbb{R}^{d \times d}$ est la matrice de covariance. Dans nos expériences, nous utilisons $d = 100$, $\mu = 0$ et Σ est une matrice de Toeplitz à corrélations décroissantes :

$$\Sigma_{ij} = \rho^{|i-j|}, \quad \rho = 0,95. \quad (4.6)$$

Elle constitue la *distribution de référence* du benchmark : tout algorithme MCMC correct doit converger vers elle, et les estimateurs peuvent être comparés à la vérité analytique exacte ($\mathbb{E}[\theta] = \mu$, $\text{Var}(\theta_i) = \Sigma_{ii} = 1$).

La matrice de Toeplitz avec $\rho = 0,95$ introduit de très fortes corrélations entre les composantes : deux variables séparées de k indices ont une corrélation de $0,95^k$, soit encore 0,60 pour $k = 10$ et 0,36 pour $k = 20$. Ces corrélations allongent considérablement les contours de la distribution et rendent inefficaces les proposals isotropes : un pas adapté à une direction l'est rarement pour une autre.

En haute dimension, même sans pathologie de courbure, cette distribution révèle la *malédiction de la dimension* pour les algorithmes à proposal isotrope. La masse se concentre sur une coquille ellipsoïdale dont les axes sont dictés par les valeurs propres de Σ (VERSHYNIN 2018). Le rapport entre la plus grande et la plus petite valeur propre de Σ croît rapidement avec ρ et d , rendant l'exploration uniforme de l'espace impossible avec un proposal sphérique. Le pas optimal vérifie alors $\sigma^* = 2,38 / \sqrt{d} \approx 0,24$ en dimension $d = 100$ (ROBERTS, GELMAN et GILKS 1997), mais ce résultat est établi pour $\Sigma = I_d$: en présence de fortes corrélations, un proposal adaptatif tenant compte de la structure de Σ devrait être indispensable.

Cette distribution remplit deux rôles dans le benchmark. D'une part, elle fournit un *cas test de validation* : l'erreur absolue entre les estimateurs MCMC et la vérité analytique exacte quantifie directement la qualité de l'échantillonnage. D'autre part, en dimension $d = 100$ avec de fortes corrélations, elle illustre le comportement des algorithmes dans un espace représentatif des problèmes de calage industriels, où les paramètres incertains sont rarement indépendants.

4.4.2 Résultats

4.5 Synthèse




FIGURE 4.1 – Distributions cibles de référence

Chapitre 5

Applications réelles

Annexe

Bibliographie

Bibliographie

- AGAPIOU, Sergios et al. (2017). « Importance Sampling : Intrinsic Dimension and Computational Cost ». In : *Statistical Science* 32.3, p. 405-431. DOI : [10.1214/17-STS611](https://doi.org/10.1214/17-STS611).
- BELLMAN, Richard E. (1957). *Dynamic Programming*. Princeton : Princeton University Press.
- BROOKS, Stephen P. et Andrew GELMAN (1998). « General methods for monitoring convergence of iterative simulations ». In : *Journal of Computational and Graphical Statistics* 7.4, p. 434-455. DOI : [10.1080/10618600.1998.10474787](https://doi.org/10.1080/10618600.1998.10474787).
- COWLES, Mary Kathryn et Bradley P. CARLIN (1996). « Markov Chain Monte Carlo Convergence Diagnostics : A Comparative Review ». In : *Journal of the American Statistical Association* 91.434, p. 883-904. DOI : [10.1080/01621459.1996.10476956](https://doi.org/10.1080/01621459.1996.10476956).
- GELMAN, Andrew, Gareth O. ROBERTS et Walter R. GILKS (1996). « Efficient Metropolis jumping rules ». In : *Bayesian Statistics* 5, p. 599-608.
- GELMAN, Andrew et Donald B. RUBIN (1992). « Inference from Iterative Simulation Using Multiple Sequences ». In : *Statistical Science* 7.4, p. 457-472. DOI : [10.1214/ss/1177011136](https://doi.org/10.1214/ss/1177011136).
- GEWEKE, John (1992). « Evaluating the Accuracy of Sampling-Based Approaches to the Calculation of Posterior Moments ». In : *Bayesian Statistics* 4. Sous la dir. de José M. BERNARDO et al. Oxford : Oxford University Press, p. 169-193.
- HAARIO, Heikki, Marko LAINE et al. (2006). « DRAM : efficient adaptive MCMC ». In : *Statistics and Computing* 16.4, p. 339-354. DOI : [10.1007/s11222-006-9438-0](https://doi.org/10.1007/s11222-006-9438-0).
- HAARIO, Heikki, Eero SAKSMAN et Johanna TAMMINEN (2001). « An adaptive Metropolis algorithm ». In : *Bernoulli* 7.2, p. 223-242. DOI : [10.2307/3318737](https://doi.org/10.2307/3318737).
- HASTINGS, W. Keith (1970). « Monte Carlo Sampling Methods Using Markov Chains and Their Applications ». In : *Biometrika* 57.1, p. 97-109. DOI : [10.1093/biomet/57.1.97](https://doi.org/10.1093/biomet/57.1.97).
- KENNEDY, Marc C. et Anthony O'HAGAN (2001). « Bayesian Calibration of Computer Models ». In : *Journal of the Royal Statistical Society : Series B* 63.3, p. 425-464. DOI : [10.1111/1467-9868.00294](https://doi.org/10.1111/1467-9868.00294).
- METROPOLIS, Nicholas, Arianna W. ROSENBLUTH et al. (1953). « Equation of State Calculations by Fast Computing Machines ». In : *The Journal of Chemical Physics* 21.6, p. 1087-1092. DOI : [10.1063/1.1699114](https://doi.org/10.1063/1.1699114).
- METROPOLIS, Nicholas et Stanislaw ULAM (1949). « The Monte Carlo Method ». In : *Journal of the American Statistical Association* 44.247, p. 335-341. DOI : [10.1080/01621459.1949.10483310](https://doi.org/10.1080/01621459.1949.10483310).
- MEYN, Sean P. et Richard L. TWEEDIE (1993). *Markov Chains and Stochastic Stability*. London : Springer-Verlag. DOI : [10.1007/978-1-4471-3267-7](https://doi.org/10.1007/978-1-4471-3267-7).
- MIRA, Antonietta (2001). « On Metropolis-Hastings algorithms with delayed rejection ». In : *Metron* 59.3-4, p. 231-241.
- NEAL, Radford M. (2003). « Slice Sampling ». In : *The Annals of Statistics* 31.3, p. 705-767. DOI : [10.1214/aos/1056562461](https://doi.org/10.1214/aos/1056562461).
- PESKUN, Peter H. (1973). « Optimum Monte Carlo sampling using Markov chains ». In : *Biometrika* 60.3, p. 607-612. DOI : [10.1093/biomet/60.3.607](https://doi.org/10.1093/biomet/60.3.607).

- RAFTERY, Adrian E. et Steven M. LEWIS (1992). « How Many Iterations in the Gibbs Sampler ? » In : sous la dir. de José M. BERNARDO et al., p. 763-773.
- RASTRIGIN, L. A. (1974). *Systems of Extremal Control*. Moscow : Mir.
- ROBERT, Christian P. et George CASELLA (2004). *Monte Carlo Statistical Methods*. 2^e éd. New York : Springer. DOI : [10.1007/978-1-4757-4145-2](https://doi.org/10.1007/978-1-4757-4145-2).
- (2009). *Introducing Monte Carlo Methods with R*. New York : Springer. DOI : [10.1007/978-1-4419-1576-4](https://doi.org/10.1007/978-1-4419-1576-4).
- ROBERTS, Gareth O., Andrew GELMAN et Walter R. GILKS (1997). « Weak Convergence and Optimal Scaling of Random Walk Metropolis Algorithms ». In : *The Annals of Applied Probability* 7.1, p. 110-120. DOI : [10.1214/aoap/1034625254](https://doi.org/10.1214/aoap/1034625254).
- ROSENBROCK, H. H. (1960). « An Automatic Method for Finding the Greatest or Least Value of a Function ». In : *The Computer Journal* 3.3, p. 175-184. DOI : [10.1093/comjnl/3.3.175](https://doi.org/10.1093/comjnl/3.3.175).
- RUBINSTEIN, Reuven Y. (1981). *Simulation and the Monte Carlo Method*. New York : John Wiley & Sons.
- TIERNEY, Luke (1994). « Markov chains for exploring posterior distributions ». In : *The Annals of Statistics* 22.4, p. 1701-1762. DOI : [10.1214/aos/1176325750](https://doi.org/10.1214/aos/1176325750).
- TIERNEY, Luke et Antonietta MIRA (1999). « Some adaptive Monte Carlo methods for Bayesian inference ». In : *Statistics in Medicine* 18.17-18, p. 2507-2515. DOI : [10.1002/\(SICI\)1097-0258\(19990915/30\)18:17/18](https://doi.org/10.1002/(SICI)1097-0258(19990915/30)18:17/18).
- VERSHYNIN, Roman (2018). *High-Dimensional Probability : An Introduction with Applications in Data Science*. Cambridge : Cambridge University Press. DOI : [10.1017/9781108231596](https://doi.org/10.1017/9781108231596).
- WILKS, Samuel S. (1938). « The large-sample distribution of the likelihood ratio for testing composite hypotheses ». In : *The Annals of Mathematical Statistics* 9.1, p. 60-62. DOI : [10.1214/aoms/1177732360](https://doi.org/10.1214/aoms/1177732360).